گزارش مستقل ممیزی فنی RAG_finance

وضعیت Phase 2، معماری RAG، آمادگی محصول و مسیر دانش‌بنیان

Repository	**Shahbazi-Amir/RAG_finance**
Branch	rag-phase2
Commit	96c0f0c7d09f4bff107ed71664a0c57ed09f3214
تاریخ	۲۰ اوت ۲۰۲۶
دامنه	ممیزی فقط‌خواندنی؛ بدون تغییر در مخزن

۱. Executive Summary

حکم نهایی کوتاه

مسیر کلان پروژه—ساخت RAG تخصصی سواد مالی بر پایه مقاله، کتاب و Transcript—**درست و قابل دفاع است**؛ اما وضعیت فعلی مخزن هنوز یک **نمونه مهندسی/تحقیقاتی با دو نسل متفاوت** است، نه محصول Production Ready و نه پرونده آماده ارزیابی دانش‌بنیان.

مخزن دو لایه دارد:

1. **نسل قدیمی Demo**: زنجیره کامل Streamlit → Retrieval → Generation → Qdrant → Embedding که روی ۷۶ مقاله و ۱۶۸ Chunk ساخته شده است. این لایه برای اثبات امکان‌پذیری خوب است، اما Dense-only، بدون Reranker، بدون Hybrid Search، بدون Citation در سطح ادعا و با ارزیابی بسیار کوچک است.
2. **نسل جدید Phase 2**: Website Ingestion V2 برای ۵۲۹ مقاله با Validation، Hash، Raw Snapshot، Discovery، Extraction، Manifest، Stable ID و Quality Summary. این بخش نسبت به Demo قدیمی بسیار حرفه‌ای‌تر است، ولی هنوز Notebookمحور است و خروجی‌های اصلی آن به‌علت .gitignore داخل مخزن نیستند.

کتاب‌ها و Transcriptها به‌عنوان **ورودی داده** در Repository وجود دارند: ۷ فایل DOCX کتاب و ۲۱۳ فایل Markdown در مجموعه نهایی Transcript. بااین‌حال Pipeline استاندارد و قابل بازتولید Phase 2 برای این دو منبع، Schema رسمی، Manifest مستقل، Chunking منبع‌محور و Lineage یکپارچه هنوز وجود ندارد.

امتیاز پیشرفت واقعی

بر اساس ۳۸ بند Roadmap ارائه‌شده و روش امتیازدهی MISSING=0، PARTIAL=0.5، DONE=1 و حذف NOT NEEDED از مخرج:

- **پیشرفت Phase 2: حدود ۳۹٪** (14.5 / 37)
- **آمادگی Production: حدود ۲۰٪**
- **آمادگی پرونده فنی دانش‌بنیان: حدود ۲۵٪**

این درصدها اندازه‌گیری مدیریتی‌اند، نه گواهی رسمی. دلیل اختلاف آن‌ها این است که داشتن داده و Notebook با داشتن محصول پایدار، قابل آزمون، قابل استقرار و قابل دفاع نزد ارزیاب یکسان نیست.

تصمیم Go / No-Go

- ادامه پروژه: **GO**
- ارائه فوری برای ارزیابی دانش‌بنیان: **NO-GO**
- ادامه با همان معماری Demo قدیمی: **NO-GO**

- ادامه با معماری سه‌منبعی، Safety، Citation، Reranking، Hybrid Retrieval، Provenance و Evaluation: **GO**

پنج فاصله بحرانی

1. نبود Dataset یکپارچه و Versioned برای هر سه منبع.
2. نبود استناد دقیق به صفحه/فصل/زمان و نبود Claim-level Citation.
3. نبود Benchmark و Golden Dataset معتبر؛ ارزیابی فعلی فقط ۱۰ سؤال است.
4. نبود تست، Lockfile، Docker، CI و مسیر اجرای قابل بازتولید.
5. نبود پرونده R&D و شواهد تمایز فنی؛ در وضع فعلی ارزیاب می‌تواند پروژه را «مدل آماده + Vector DB» تلقی کند.

۲. روش ممیزی و سطح اطمینان شواهد

شواهد مستقیم بررسی‌شده

- Tree کامل شاخه rag-phase2: ۹۰۴ Entry و ۷۱۳ فایل.
- Metadata مخزن، Branch و Commit head.
- requirements.txt، .gitignore، README و config/settings.py.
- کدهای app.py و ماژول‌های src/cache، src/generation، src/retrieval، src/embeddings و src/pipeline.
- Notebook جدید notebooks/phase2/01_website_ingestion.ipynb شامل ۱۷۵ Cell؛ هر ۸۲ Code Cell اجرا شده و Error ذخیره‌شده ندارد.
- Notebookهای قدیمی Generation، Retrieval، Vector Store، Embedding، Chunking، Preprocessing، Pipeline و Evaluation.
- website_manifest_v1.json با ۵۲۹ رکورد.
- فایل ارزیابی ۱۰ سؤالی و چند نمونه Transcript و اسناد بازبینی آن‌ها.
- تاریخچه Commitهای اصلی شاخه، شامل اضافه‌شدن Transcriptها و کتاب‌ها در ۲۰ اوت ۲۰۲۶.

شواهد غیرقابل بازاجرای مستقل در این ممیزی

خروجی‌های زیر در .gitignore هستند و در Tree Commit بررسی‌شده وجود ندارند:

- /data/phase2/raw
- data/phase2/interim/website_extracted_v2.json
- reports/phase2/data_quality/website_extraction_v2.json
- reports/phase2/ingestion/website_ingestion_v2.json
- Vector Store و Embeddingهای تولیدشده

بنابراین صحت اعداد ۵۲۹/۵۲۹ از دو مدرک پشتیبانی می‌شود: خروجی‌های ذخیره‌شده داخل Notebook و فایل Manifest؛ اما Snapshotهای ignored در این ممیزی مجدداً اجرا یا Hash-verify نشدند. برای ممیزی رسمی باید Artifact Registry یا Dataset Release قابل دریافت وجود داشته باشد.

۳. وضعیت فعلی Repository

۳.۱ ساختار کلیدی

مسیر	وضعیت واقعی	ارزیابی
README.md	معرفی مفهومی RAG؛ هنوز از مقاله و کتاب نام می‌برد و وضعیت سه‌منبعی جدید را منعکس نمی‌کند	ناقص/قدیمی

مسیر	وضعیت واقعی	ارزیابی
notebooks/phase2/01_website_ingestion.ipynb	Pipeline کامل Website V2، ۵۲۹ مقاله، Hash و Validation	قوی‌ترین دارایی فنی فعلی
data/phase2/manifests/website_manifest_v1.json	۵۲۹ رکورد با Stable ID و Version	مفید ولی محدود به وب‌سایت
data/books/	۷ فایل DOCX، شامل نسخه‌های ظاهراً مشابه/بازطراحی‌شده	داده موجود؛ Pipeline وجود ندارد
data/transcripts/final/	۲۱۳ فایل MD در ۷ مجموعه	داده ارزشمند؛ Schema و Timestamp یکنواخت نیست
notebooks/02...10	زنجیره RAG قدیمی روی ۷۶ مقاله و ۱۶۸ Chunk	Demo/Prototype
src/	چهار جزء اصلی RAG و Cache	کد ساده و قابل فهم؛ نه Production Grade
app.py	Streamlit chat، تاریخچه JSON و نمایش Source	Demo UI
data/evaluation/...json	۱۰ سؤال؛ ۸ in-scope و ۲ out-of-scope	Smoke test، نه Benchmark
tests/	وجود ندارد	بحرانی
.github/workflows/	وجود ندارد	CI/CD وجود ندارد
docs/	وجود ندارد	مستندسازی معماری/عملیات وجود ندارد
Docker/Compose	وجود ندارد	استقرار بازتولیدپذیر وجود ندارد

۳.۲ شاخه و تاریخچه

- Default branch مخزن main است، اما ممیزی روی rag-phase2 انجام شد.
- Head شاخه: 96c0f0c7 با پیام ogtanos aram added در ۲۰ اوت ۲۰۲۶.
- Commit قبلی f46501cc هفت فایل کتاب را اضافه کرده است.
- Commit 9e2e1ebf مجموعه‌های چهلستون/بانک ملت و فایل‌های مرتبط را اضافه کرده است.
- تاریخچه قدیمی‌تر از June–July 2026 نشان‌دهنده ساخت مرحله‌ای Demo: ingestion، chunking، embedding، app، cache، generation، retrieval، Qdrant و evaluation است.
- Branch محافظت‌شده نیست و Required Status Check ندارد.
- Commit head امضاشده/Verified نیست.
- نام و کیفیت پیام Commitها یکنواخت نیست (just، ogtanos aram added و غلط‌های نگارشی). این موضوع مانع فنی محصول نیست، اما برای پرونده قابل ممیزی و مدیریت R&D ضعیف است.

۳.۳ داده‌های موجود

- ۵۲۹ مقاله در Website Manifest.
- ۷ فایل DOCX کتاب؛ چند فایل ممکن است نسخه‌های متفاوت یک اثر باشند. چون Deduplication و Canonical Book Registry وجود ندارد، تعداد «اثر مستقل» از روی نام فایل قطعی نیست.
- ۲۱۳ فایل Markdown زیر /data/transcripts/final:
- asre_shirin: ۲۶

- chehelstion_finup_ketabbaz_bankmellat: ۵۵
- dar-jostojo-final-C:\: ۵۹، که بخشی از آن‌ها فایل‌های Audit/Extracted هستند و همگی Episode مستقل نیستند
- khane-to: ۱۳
- mq: ۸
- tarbiat-morabi: ۱۴
- uni-tehran: ۳۸

> **عدد ۲۱۳ تعداد فایل Markdown است، نه تعداد قطعی Episode مستقل. برای عدد رسمی باید Transcript Manifest ساخته شود و فایل‌های محتوایی، Audit، Candidate و Supplemental از هم تفکیک شوند.**

۳.۴ Website Ingestion V2

موارد مثبت:

- کشف Pagination بدون Hard-code شدن تعداد صفحات.
- ۵۲۹ مقاله یکتا و Canonical URL بر اساس article_id.
- Stable ID به شکل <website:<article_id>.
- ذخیره Raw HTML و source.json.
- SHA-256 روی Bytes خام.
- Validation ساختاری HTML.
- Retry، Resume و رفع Root Cause خطای Cookie/HTTP 400.
- استخراج Tags، Author، Body، Title و Metadata.
- نرمال‌سازی Soft Hyphen و متن.
- گزارش خروجی Title/Body/Author/Hash ۵۲۹ :Notebook غیرخالی.

موارد منفی:

- کل Pipeline در Notebook است؛ Package/CLI/Job مستقل ندارد.
- Manifest Commitشده هنوز status=discovered و author=null دارد، حتی با وجود تکمیل استخراج در خروجی Notebook؛ یعنی State نهایی و Manifest همگام نیستند.
- version=1 صرفاً یک فیلد است؛ Dataset Versioning واقعی، Parent Version، Changelog و Snapshot Hash وجود ندارد.
- Incremental Update فقط Resume دانلودهای موجود را پوشش می‌دهد؛ تشخیص Add/Change/Delete و سیاست Reprocessing مستند نیست.
- گزارش‌های تولیدشده ignored و در دسترس ممیز نیستند.
- Notebook به مسیر مطلق macOS وابسته است و Reproducibility محیطی ندارد.
- Assertions و تست خودکار وجود ندارد؛ Validationها عمدتاً print هستند.

۳.۵ Video/Transcript

موارد مثبت:

- حجم قابل توجه متن بازبینی‌شده و Curated.
- Metadata انسانی در ابتدای بسیاری از فایل‌ها: برنامه، قسمت، موضوع، مدت، منبع و وضعیت بازبینی.
- در dar-jostojo شواهدی از Raw/Machine/Reviewed/Final و Audit اختلاف‌ها وجود دارد؛ این یک دارایی R&D ارزشمند است.

موارد منفی:

- Schema رسمی و Machine-readable واحد وجود ندارد؛ Metadata در Markdown آزاد نوشته شده است.
- Timestamp در سطح Segment/Sentence حفظ نشده و Citation زمانی قابل اتکا نیست.
- Speaker ID در بعضی مجموعه‌ها وجود دارد و در بعضی‌ها نه؛ یکنواخت نیست.
- Start/End Time، Audio Asset ID، Segment Hash، ASR Confidence و Revision Lineage عمومی وجود ندارد.
- فایل‌های Candidate Difference، Supplemental، Episode و Review در یک Tree داده‌ای کنار هم‌اند و هنوز نقش هرکدام در Knowledge Base با Manifest تعیین نشده است.
- Chunker، Validator و Quality Report اختصاصی Transcript وجود ندارد.

Book ۳.۶

موارد مثبت:

- فایل‌های Word در Repository حاضرند.
- نسخه‌های بازطراحی RTL می‌تواند استخراج فارسی را ساده‌تر کند.

موارد منفی:

- هیچ Book Manifest یا Canonical Work ID وجود ندارد.
- نسخه‌های مشابه یک کتاب از هم تفکیک نشده‌اند؛ Risk ورود محتوای تکراری بالاست.
- Chapter/Heading Extraction، Paragraph Anchor، Page/Location Mapping، Footnote/Table handling و Cleaning وجود ندارد.
- صفحه در DOCX پایدار نیست؛ برای Citation باید یا PDF مرجع نهایی ثبت شود، یا Anchor پایدار فصل/بخش/پاراگراف ساخته شود.
- حقوق نشر، مجوز استفاده و دامنه مجاز نمایش متن در Repository مستند نشده است.

RAG ۳.۷ و Application قدیمی

موارد مثبت:

- اجزای Generator، Retriever، Embedder و Cache از هم جدا شده‌اند.
- Qdrant Payload شامل chunk_id، article_id، title، url و text است.
- Prompt از مدل می‌خواهد خارج از Context پاسخ ندهد.
- UI منابع بازیابی‌شده را نمایش می‌دهد.
- برای دو سؤال out-of-scope پاسخ «در منابع موجود پاسخ کافی پیدا نشد» ثبت شده است.

موارد منفی:

- RAG فعلی روی Dataset قدیمی ۷۶ مقاله/۱۶۸ Chunk است، نه Dataset سه‌منبعی جدید.
- Retrieval فقط Dense Vector Search است؛ Sparse/BM25، Hybrid و Reranking ندارد.
- Threshold بازیابی و Answerability Model وجود ندارد؛ Abstention وابسته به رفتار LLM است.
- Citation صرفاً فهرست Sourceهای Retrieval است، نه اثبات اینکه هر ادعای پاسخ توسط کدام Span پشتیبانی شده است.
- Context Builder فقط Concatenation ساده Top-k است؛ کنترل Source Balance، Diversity، Token Budget، Dedup و Conflict ندارد.
- Cache Key فقط متن Normalizeشده سؤال است؛ Prompt Version، Model Version، Dataset Version و top_k در کلید نیستند. بنابراین پاسخ قدیمی می‌تواند بعد از تغییر Knowledge Base باقی بماند.
- در مسیر Cache، داده retrieved_chunks می‌تواند با سیاست خالی‌کردن منابع در حالت Abstention ناسازگار شود.

- تاریخچه Chat در JSON مشترک ذخیره می‌شود؛ Multi-user isolation، Privacy، Retention و Concurrent write ندارد.
- هیچ Rate Limit، Auth، Audit Log، Observability یا API Contract وجود ندارد.
- ادعای پشتیبانی از ۱۵۰۰ کاربر در README هیچ Load Test یا معماری Deployment پشتیبان ندارد.

۴. ماتریس تطبیق با Roadmap فاز ۲

Phase 2 Foundation

مورد	وضعیت	مدرک/فاصله
Freeze Phase 1	PARTIAL	Demo قدیمی قابل مشاهده است؛ Tag/Release رسمی، Baseline Report و Freeze policy نیست
Baseline	DONE	۷۶ مقاله/۱۶۸ Chunk برای Demo و ۵۲۹ مقاله برای Website V2 ثبت شده
Document Schema	PARTIAL	Schema ضمنی Website وجود دارد؛ JSON Schema مشترک سه‌منبعی نیست
Stable IDs	PARTIAL	Website ID مناسب است؛ Book/Video ID استاندارد نیست
Manifest	PARTIAL	فقط Website Manifest وجود دارد
Dataset Versioning	PARTIAL	فیلد Version هست؛ Release/Hash/Parent/Changelog نیست

Website Pipeline

مورد	وضعیت	مدرک/فاصله
Discovery	DONE	۵۲۹ مقاله و Pagination خودکار
Raw Storage	DONE	HTML + source.json؛ خروجی ignored ولی اجرای Notebook ثبت شده
Extraction	DONE	۵۲۹ رکورد و Metadata
Validation	DONE	Hash و Structure Validation؛ ۵۲۹ معتبر در خروجی Notebook
Incremental Update	PARTIAL	Resume هست؛ Diff/Delete/Reprocess policy نیست
Crawl Report	PARTIAL	تولید می‌شود ولی Artifact قابل ممیزی در Repository/Release نیست
Processing	DONE	Extraction و نرمال‌سازی فارسی اولیه کامل است
Chunking	MISSING	Chunking V2 برای ۵۲۹ مقاله وجود ندارد

Video Pipeline

مورد	وضعیت	مدرک/فاصله
Transcript Schema	PARTIAL	Metadata انسانی موجود، Contract یکنواخت و JSON Schema نیست
Validation	PARTIAL	بازبینی انسانی وجود دارد؛ Validator خودکار و Coverage Report نیست
Normalization	PARTIAL	متن‌های نهایی پاک‌سازی شده‌اند؛ قواعد واحد و تست‌شده نیست
Timestamp Preservation	MISSING	Start/End زمان Segmentها در خروجی نهایی نیست
Chunking	MISSING	Pipeline اختصاصی Video وجود ندارد

Book Pipeline

مورد	وضعیت	مدرک/فاصله
PDF/EPUB Processing	NOT NEEDED	ورودی فعلی DOCX است؛ به‌جای آن DOCX/PDF-reference processing باید اضافه شود
Chapter Extraction	MISSING	Pipeline یا خروجی فصل‌بندی دیده نشد
Page Metadata	MISSING	Page/Location یا Paragraph Anchor وجود ندارد
Cleaning	MISSING	قواعد پاک‌سازی و QA کتاب وجود ندارد
Chunking	MISSING	Chunking اختصاصی کتاب وجود ندارد

Unified Dataset

مورد	وضعیت	مدرک/فاصله
Common Schema	MISSING	سه منبع هنوز Contract واحد ندارند
Deduplication	MISSING	Dedup بین نسخه کتاب/مقاله/ویدیو وجود ندارد
Quality Report	PARTIAL	فقط Website Quality Summary وجود دارد

RAG Layer

مورد	وضعیت	مدرک/فاصله
Embedding	PARTIAL	Demo قدیمی؛ Dataset جدید Embedding نشده
Vector Database	PARTIAL	Qdrant Demo؛ Collection versioning و migration نیست
Retrieval	PARTIAL	Dense-only و بدون ارزیابی Retrieval
Hybrid Search	MISSING	BM25/Sparse وجود ندارد
Reranking	MISSING	Cross-encoder/LLM reranker وجود ندارد
Context Builder	PARTIAL	Concatenation ساده؛ Budget/Diversity/Conflict ندارد
Citation	PARTIAL	Source list هست؛ Claim-level و Page/Time citation نیست

Evaluation

مورد	وضعیت	مدرک/فاصله
Golden Dataset	MISSING	۱۰ سؤال بدون Gold Evidence/Answer
Benchmark	PARTIAL	یک Smoke Test ده‌سؤالی وجود دارد
Regression Test	MISSING	Gate خودکار و مقایسه نسخه‌ها نیست
Metrics	MISSING	فقط شمارش Reject دو سؤال؛ Retrieval/Faithfulness/Citation metrics نیست

۵. بررسی معماری «Professional Financial Literacy Advisory RAG»

Multi-source Architecture

در سطح Intent درست است، اما در پیاده‌سازی **هنوز Multi-source نیست**. سه منبع در Storage دیده می‌شوند، ولی فقط Website V2 Pipeline دارد و RAG قدیمی فقط مقالات را مصرف می‌کند. Multi-source زمانی محقق است که هر منبع Adapter مستقل داشته باشد و همه در Common Document Contract ادغام شوند.

Data Lineage

برای وب‌سایت بخشی از Lineage وجود دارد: URL → Raw HTML → Hash → Extracted Record. برای کتاب و Transcript، Lineage یکنواخت وجود ندارد. Lineage کامل باید این زنجیره را ثبت کند:

→ source asset → source version/hash → extraction run → normalization version → document ID → chunk ID → embedding model/version → index version → retrieval event → answer → cited evidence

Citation و دفاع‌پذیری

Citation فعلی واقعی و کافی نیست. نمایش عنوان/URL منابع Retrieval ثابت نمی‌کند جمله پاسخ از همان منابع آمده است. Citation حرفه‌ای باید:

- برای Website به URL + Article ID + Span/Paragraph Anchor متصل باشد.
- برای Book به Work/Edition + Chapter + Page یا Paragraph Anchor متصل باشد.
- برای Video به Program/Episode + Start/End Timestamp متصل باشد.
- هر Claim مهم پاسخ را به یک یا چند Evidence Span نگاشت کند.
- Citation Entailment را بررسی کند: آیا Evidence واقعاً Claim را پشتیبانی می‌کند؟

کنترل Hallucination

Prompt به‌تنهایی کنترل Hallucination محسوب نمی‌شود. کنترل قابل دفاع حداقل به این اجزا نیاز دارد:

1. Retrieval Quality Gate و حداقل Evidence Coverage.
2. Answerability/Abstention classifier کالیبره‌شده.
3. تولید پاسخ در قالب Claimهای قابل Cite.
4. Citation verification یا entailment check.
5. سیاست Freshness، Conflict و Unknown.
6. Regression suite برای سؤال‌های خارج از دامنه، گمراه‌کننده و تزریق Prompt.

معماری هدف پیشنهادی

1. **Source adapters:** Website، Book و Video؛ مستقل ولی با Contract مشترک.
2. **Immutable raw zone:** محتوا، حقوق منبع، Hash و زمان دریافت.
3. **Canonical document layer:** Schema واحد، Version، Stable ID و Lineage.
4. **Source-aware chunking:** فصل/پاراگراف، Topic Shift و Timestamp.
5. **Dual index:** Dense + Sparse/BM25 با فیلتر Metadata.
6. **Reranker:** مدل مناسب فارسی یا Multilingual و آزمایش مقایسه‌ای.
7. **Context compiler:** Token budget، Source balance، MMR/Diversity، Dedup و conflict grouping.
8. **Grounded generation:** پاسخ آموزشی، Claim IDs و Citation اجباری.
9. **Safety/policy layer:** مرزبندی آموزش با توصیه سرمایه‌گذاری شخصی.

10. **Evaluation/observability:** نسخه‌محور، قابل بازتولید و دارای Release Gate.

۶. ارزیابی آمادگی دانش‌بنیان

معیار رسمی و دامنه اطمینان

منابع رسمی عمومی تأکید می‌کنند ارزیابی بر محصول شرکت و تشخیص کارگروه متکی است؛ آیین‌نامه اجرایی نیز مسئولیت تدوین حوزه‌ها و معیارها را به ساختار ارزیابی می‌دهد. منابع رسمی صندوق نوآوری، «سطح فناوری/پیچیدگی»، «دانش فنی» و «نمونه اولیه» را از معیارهای اصلی معرفی کرده‌اند. همچنین آخرین نسخه معیارها و فهرست کالا/خدمت باید در سامانه رسمی زمان اقدام کنترل شود.

منابع مرجع:

- آیین‌نامه اجرایی قانون حمایت از شرکت‌های دانش‌بنیان — صندوق نوآوری و شکوفایی — https://www.inif.ir/-regulations-executive-law
- اصلاح آیین‌نامه اجرایی و وظایف کارگروه — پایگاه قوانین و مقررات — https://qavanin.ir/Law/TreeText?IDS=7646595681372737421
- توضیح رسمی صندوق درباره معیارهای سطح فناوری، دانش فنی و نمونه اولیه — https://www.inif.ir/fullcontent/-/asset_publisher/YASjeuXFqbaQ/content/id/646562

آیا پروژه فعلی فقط «مدل آماده + Vector DB» است؟

در Demo فعلی: تا حد زیادی بله. اجزای اصلی، API سازگار OpenAI، Qdrant و Streamlit هستند و Retrieval نیز Dense-only است. Website Ingestion V2 و بازبینی Transcriptها نشانه‌های مهندسی اختصاصی ارزشمندند، اما هنوز به محصول نهایی متصل و با Benchmark اثبات نشده‌اند.

وضعیت مؤلفه‌های دفاع‌پذیری

مؤلفه	وضعیت فعلی	برای دفاع چه لازم است؟
معماری اختصاصی	PARTIAL	Architecture Decision Record و پیاده‌سازی سه‌منبعی
Pipeline اختصاصی داده	PARTIAL	Website قوی؛ Book/Video باید هم‌سطح شوند
Normalization فارسی	PARTIAL	قواعد، Corpus خطا، تست و Ablation
Data Engineering	PARTIAL	Orchestration، lineage، artifacts و quality gates
Versioning	PARTIAL	Dataset/Index/Prompt/Model releases
Evaluation Framework	MISSING	Golden set، metrics، dashboards، gates
Benchmark	MISSING	Baseline comparisons و گزارش آماری
Retrieval Optimization	MISSING	Hybrid، reranking، tuning و ablation
Citation System	PARTIAL	Claim-level page/time/span citations
Knowledge Engineering	PARTIAL	Taxonomy، source policy، conflict/freshness
Automated Testing	MISSING	unit/integration/data/eval/security/load
Reproducibility	MISSING	Docker، pinned deps، CLI، immutable artifacts

ریسک‌های خاص پرونده

1. **مالکیت و مجوز داده:** عبارت knowledge_owner=Dr. Komeil Roudi برای تمام ۵۲۹ مقاله، به‌تنهایی سند حقوقی مالکیت یا مجوز نیست. قرارداد/مجوز استفاده از مقاله، کتاب، صوت و Transcript باید جداگانه موجود باشد.
2. **تکرار محتوا:** چند نسخه کتاب و همپوشانی مقاله/ویدیو می‌تواند Benchmark و Retrieval را مصنوعی بهبود دهد.

3. **وابستگی به سرویس آماده:** اگر تمایز در Data/Knowledge/Retrieval/Safety اثبات نشود، پرونده ممکن است Integrator ساده تلقی شود.
4. **نبود شواهد R&D:** Commitها تاریخچه کار را نشان می‌دهند، ولی فرضیه، آزمایش، نتیجه منفی، انتخاب معماری و مقایسه علمی ثبت نشده است.
5. **محصول نبودن:** Notebook و Streamlit Demo به‌تنهایی نمونه محصول قابل ارزیابی سازمانی نیست.

نتیجه دانش‌بنیان

- **قابلیت بالقوه:** دارد.
- **آمادگی فعلی برای تأیید:** کافی نیست.
- **شرط تبدیل شدن به پرونده قوی:** باید ارزش فنی حول «سامانه دانش‌محور فارسیِ قابل استناد و ایمن برای آموزش مالی» اثبات شود، نه حول استفاده از LLM و Vector DB.

۷. تفاوت «دستیار هوشمند سواد مالی» با «جستجوی متن»

جستجوی متن	دستیار هوشمند آموزشی مالی
چند سند مشابه برمی‌گرداند	سؤال را تحلیل و هدف آموزشی را تشخیص می‌دهد
مسئولیت صحت پاسخ ندارد	پاسخ Grounded با Claim-level Citation می‌سازد
معمولاً Unknown را تشخیص نمی‌دهد	در نبود Evidence مناسب صریحاً Abstain می‌کند
تفاوت آموزش/مشاوره را نمی‌فهمد	Intent و Risk را طبقه‌بندی می‌کند
Context ثابت Top-k	Context متنوع، dedupشده و متناسب با نوع سؤال
بدون مسیر یادگیری	توضیح مرحله‌ای، مثال، تمرین و پیگیری یادگیری
Source list ساده	صفحه/فصل/زمان و توضیح نقش هر منبع
Score شباهت	Confidence کالیبره‌شده از چند سیگنال

قابلیت‌های ضروری محصول

- پاسخ مستند با Citation در سطح Claim.
- تشخیص «پاسخ کافی وجود ندارد» با Threshold کالیبره‌شده.
- تفکیک Intent: آموزش عمومی، برنامه‌ریزی مالی عمومی، درخواست توصیه شخصی، پیش‌بینی بازار و معامله.
- امتناع/هشدار برای توصیه سرمایه‌گذاری شخصی بدون داده و مجوز مناسب.
- توضیح اینکه پاسخ از چه نوع منابعی ساخته شده و اختلاف منابع چیست.
- Confidence به‌صورت بالا/متوسط/پایین یا عدد کالیبره، نه Score خام Qdrant.
- ثبت Trace، Feedback و Evidence برای Audit.
- Privacy و عدم ذخیره اطلاعات حساس مالی بدون رضایت و سیاست Retention.

روش صحیح Confidence

Confidence نباید از «اعتماد مدل» یا فقط شباهت برداری ساخته شود. پیشنهاد:

Confidence = calibrated(retrieval coverage, evidence agreement, citation entailment, source quality, answerability margin, freshness)

عدد نهایی باید روی Validation Set کالیبره شود و Reliability Diagram/Brier Score داشته باشد.

۸. Roadmap اصلاحی اولویت‌بندی‌شده

P0 — ضروری؛ پیش از توسعه قابلیت‌های نمایشی بیشتر

P0.1 تثبیت Baseline و ساخت سند معماری

خروجی‌ها:

- docs/architecture/system-context.md
- docs/architecture/data-flow.md
- docs/adr/ADR-001-multisource-contract.md
- docs/phase1-baseline.md
- Tag/Release رسمی برای Demo قدیمی

معیار پایان: هر عضو تیم بداند Dataset قدیمی و Phase 2 جدید چه تفاوتی دارند و کدام مسیر Canonical است.

P0.2 ساخت Data Contract واحد

خروجی‌ها:

- schemas/source_manifest.schema.json
- schemas/document.schema.json
- schemas/chunk.schema.json
- schemas/retrieval_event.schema.json

فیلدهای حداقلی Document:

document_id, source_type, source_id, source_version, title, language, authors, rights, canonical_uri, content_hash, extracted_at, extractor_version, quality_status, parent_document_id, location, text

فیلدهای حداقلی Chunk:

chunk_id, document_id, chunker_version, text, text_hash, start_char, end_char, heading_path, page, timestamp_start, timestamp_end, speaker, source_uri

P0.3 تکمیل Pipeline کتاب و ویدیو

خروجی‌ها:

- /src/ingestion/books
- /src/ingestion/videos
- Manifest مستقل هر منبع
- Validation Report و Reject Queue
- Stable IDs و Lineage

معیار پایان: Run دوباره همان ورودی، خروجی Deterministic با ID و Hash یکسان بسازد.

P0.4 Dataset Versioning و Artifact Registry

خروجی‌ها:

- Dataset release مانند kb-2026.08.1
- dataset_manifest.json با Hash تمام اجزا
- Changelog و Parent Version
- محل Artifact خارج Git برای Raw/Interim/Index

معیار پایان: یک ممیز با یک دستور بتواند Dataset مشخص را بازیابی و Verify کند.

P0.5 Golden Dataset و Safety Policy

حداقل ۳۰۰ سؤال در نسخه اول:

- ۱۲۰ سؤال factoid/conceptual
- ۶۰ سؤال multi-hop
- ۴۰ سؤال cross-source/conflict
- ۳۰ سؤال out-of-scope
- ۳۰ سؤال personal-advice/unsafe
- ۲۰ سؤال noisy/typo/Persian variants

برای هر سؤال: Safety Label، Intent، Difficulty، Source ID، Gold Evidence Span، Gold Answer و Acceptable Abstention.

P0.6 Retrieval قابل دفاع

- BM25/Sparse + Dense Hybrid.
- Metadata filters و Source routing.
- Reranker.
- Source-aware chunking.
- Claim-level citation و Citation verifier.
- Answerability gate.

P0.7 تست و Reproducibility

- pyproject.toml و dependency lock.
- CLIهای idempotent؛ Notebook فقط برای توضیح/آزمایش.
- Dockerfile و Compose برای App/API/Vector DB.
- Unit، Integration، Data Contract و End-to-end tests.
- CI با lint/type/test/data-smoke/eval-smoke.

P1 — مهم؛ برای محصول قابل ارائه و پرونده قوی

1. API مستقل از UI با OpenAPI و Versioning.
2. Auth، rate limit، tenant isolation و secure secret management.
3. PostgreSQL برای conversation/feedback با consent و retention.
4. Observability: trace هر پاسخ، نسخه Dataset/Index/Prompt/Model و cited spans.
5. Evaluation Dashboard و Release Gate.
6. Load Test با latency، throughput، error rate و p50/p95 cost/query.
7. Security tests: prompt injection، data exfiltration، malicious documents و PII leakage.
8. R&D dossier شامل فرضیه‌ها، Ablationها، نتایج منفی و انتخاب مدل.
9. Data rights register و قراردادهای محتوا.
10. Pilot واقعی با کاربران و تحلیل خطا/رضایت/یادگیری.

P2 — بهبود و تمایز بیشتر

1. Taxonomy/Ontology سواد مالی و Query routing موضوعی.
2. Learning path، quiz و سنجش پیش/پس از آموزش.
3. Personalization آموزشی بدون ورود به توصیه سرمایه‌گذاری شخصی.

4. Conflict-aware answers و نمایش دیدگاه‌های متفاوت.
5. Freshness-aware web recrawl و change impact analysis.
6. مدل Embedding یا Reranker بهینه‌شده برای فارسی مالی، در صورت اثبات سود با Benchmark.
7. Human review console برای اصلاح Evidence، Dataset و Safety cases.

۹. Benchmark و آزمایش‌های الزامی

Baselineهایی که باید مقایسه شوند

1. BM25 only.
2. Dense only فعلی.
3. Hybrid بدون Reranker.
4. Hybrid + Reranker.
5. Generic chunking در برابر source-aware chunking.
6. بدون Normalization فارسی در برابر Normalization نسخه‌دار.
7. بدون Citation verifier در برابر با Citation verifier.

Metrics

Retrieval: Hit Rate، nDCG@k، MRR، Recall@1/3/5/10 و source-diversity. **Generation**: Faithfulness، Answer Correctness، Completeness و Conciseness. **Citation**: Citation Recall، Citation Precision/ Coverage، Entailment و Location Accuracy. **Abstention**: Precision/Recall/F1 برای Answerable و Unanswerable، False-safe-answer rate. **Safety**: نرخ تولید توصیه شخصی نامجاز، نرخ عبور Prompt Injection و PII leakage. **Operations**: availability، error rate، throughput، latency p50/p95/p99 و cost/query. **Calibration**: Expected Calibration Error، Brier Score و Reliability Diagram.

روش علمی گزارش

- Dataset ثابت و Versioned.
- Train/Dev/Test یا Development/Test جدا.
- Bootstrap confidence interval برای اختلاف مدل‌ها.
- تحلیل خطا به تفکیک Difficulty، Intent، Source و Safety.
- ثبت Model/Prompt/Index versions، Seed، Config.
- Release فقط وقتی Regression Gate پاس شود.

۱۰. نمودارها و گزارش‌های لازم

نمودارها

1. System Context Diagram.
2. End-to-end Data Lineage Diagram.
3. سه Pipeline مستقل Website/Book/Video و نقطه ادغام.
4. Dataset composition به تفکیک Length، Topic، Source و Quality.
5. Deduplication/overlap matrix میان منابع.
6. Retrieval benchmark chart برای Baselineها.
7. Accuracy/Faithfulness/Citation dashboard.
8. Confidence reliability diagram.

9. Latency/cost/throughput chart.
10. Error taxonomy و Pareto chart.

گزارش‌ها

- Dataset Card و Data Datasheet.
- Model/System Card.
- R&D Technical Report.
- Benchmark Report.
- Safety & Responsible AI Report.
- Data Rights & Licensing Register.
- Security/Privacy Threat Model.
- Deployment/Operations Manual.
- Validation & Acceptance Report.
- Pilot Report و User Feedback Analysis.
- Change Log و Release Notes.

۱۱. ساختار پیشنهادی Repository نهایی

```
/RAG_finance
├── README.md
├── pyproject.toml
├── uv.lock | poetry.lock
├── Makefile
├── Dockerfile
├── docker-compose.yml
├── /configs
│   ├── /ingestion
│   ├── /retrieval
│   └── /evaluation
├── /schemas
│   ├── source_manifest.schema.json
│   ├── document.schema.json
│   └── chunk.schema.json
├── /src/rag_finance
│   ├── /ingestion/{website,books,videos}
│   ├── /normalization
│   ├── /chunking
│   ├── /lineage
│   ├── /indexing
│   ├── /retrieval
│   ├── /reranking
│   ├── /context
```

```
/generation ──┤ │
/citations ──┤ │
/safety ──┤ │
/evaluation ──┤ │
/api ──└ │
/data ──┤
/manifests ──┤ │
/samples ──┤ │
README.md ──└ │
/evals ──┤
/golden ──┤ │
/adversarial ──┤ │
/baselines ──└ │
/tests ──┤
/unit ──┤ │
/integration ──┤ │
/data_contract ──┤ │
/end_to_end ──└ │
/docs ──┤
/architecture ──┤ │
/adr ──┤ │
/data ──┤ │
/safety ──┤ │
/operations ──┤ │
/knowledge_based_dossier ──└ │
/reports ──┤
/benchmarks ──┤ │
/data_quality ──┤ │
/releases ──└ │
/github/workflows. ──└
```

۱۲. فهرست مدارک لازم برای ارائه دانش‌بنیان

مدارک محصول و فناوری

- معرفی محصول، مسئله، مشتری و ارزش پیشنهادی.
- Architecture Document و Data Flow.
- توضیح اجزای اختصاصی و اجزای Third-party.
- Technology Readiness/TRL evidence و Demo قابل بررسی.
- Datasheet محصول، API و Deployment topology.
- Repo/Release/Commit history و فهرست اعضای فنی.

مدارک دانش فنی و R&D

- دفترچه R&D با سؤال فنی، فرضیه، آزمایش، نتیجه و تصمیم.
- گزارش ساخت Pipeline فارسی و خطاهای ویژه فارسی/ASR/RTL.
- Benchmark و Ablation Study.
- گزارش Retrieval Optimization و Citation Verification.
- مستند Reproducibility و Test reports.
- شرح دانش فنی داخلی و وابستگی‌های خارجی.

مدارک داده و حقوق

- فهرست منابع، مالک، مجوز، تاریخ و محدودیت استفاده.
- قرارداد/اجازه استفاده از کتاب‌ها، مقالات، صوت‌ها و Transcriptها.
- Dataset Card، Manifest و Hash release.
- سیاست Privacy، Retention و حذف داده کاربر.
- سیاست امنیت و مدیریت دسترسی.

مدارک تجاری و عملیاتی

- شرکت حقوقی، تیم، نقش‌ها و سوابق.
- نمونه قرارداد/فاکتور/Pilot در صورت نیاز نوع ارزیابی.
- بازار هدف، رقبا و تمایز کمی.
- Load Test، SLA/SLO و هزینه سرویس.
- برنامه نگهداری، پشتیبانی و به‌روزرسانی Knowledge Base.

مدارک Safety و دامنه محصول

- تعریف دقیق «آموزش مالی» و موارد خارج از دامنه.
- سیاست عدم ارائه توصیه سرمایه‌گذاری شخصی بدون داده/مجوز.
- Risk Register و Incident Response.
- نتایج Red Team و سؤال‌های پرخطر.
- متن Consent، Disclaimer و مسیر ارجاع به متخصص انسانی.

۱۳. Acceptance Criteria برای پایان هر فاز

پایان Data Foundation

- سه Manifest معتبر و Common Schema پاس‌شده.
- ۱۰۰٪ Documentها Stable ID، Hash، Rights و Lineage داشته باشند.
- Duplicateهای Exact و Near-duplicate گزارش و تعیین تکلیف شوند.

پایان Retrieval

- Recall@5 هدف روی Test Set از قبل تعریف و پاس شود.
- Hybrid+Reranker به‌طور آماری از Dense-only بهتر باشد.
- Citation location accuracy برای هر سه منبع گزارش شود.

پایان Safety

- نرخ پاسخ نامجاز به درخواست توصیه شخصی زیر حد مصوب تیم باشد.

- Abstention precision/recall و False-safe-answer rate پاس شوند.
- Prompt injection suite بدون نشت داده پاس شود.

پایان Productization

- Build و Test در CI سبز.
- Deployment از محیط خالی با دستور مستند موفق.
- Trace کامل یک Answer از سؤال تا Dataset/Chunk/Citation قابل بازیابی باشد.
- Load Test ادعای ظرفیت را اثبات کند.

۱۴. مشکلاتی که باید فوراً اصلاح یا شفاف شوند

1. README باید وضعیت واقعی سه منبع، Phase 1/2 و محدودیت Demo را توضیح دهد.
2. دو محل Raw قدیمی data/raw/... و src/ingestion/data/raw/... باید از Code/Data separation برخوردار شوند؛ داده زیر src مناسب نیست.
3. requirements.txt باید Version pin و Lockfile داشته باشد.
4. مسیرهای مطلق /Users/macbookpro/... باید از Notebookها حذف و Configمحور شوند.
5. Manifest Website باید State نهایی و Versioning واقعی را بازتاب دهد.
6. Chat history و Cache تولیدی نباید به‌عنوان Artifact عادی Commit شوند؛ Privacy و Staleness risk دارند.
7. Assertions و تست‌های خودکار باید جای Print-based validation را بگیرند.
8. فایل‌های Audit Transcript نباید بدون Manifest به‌عنوان Knowledge Document وارد Index شوند.
9. نسخه‌های کتاب باید Canonicalize و حقوق استفاده‌شان ثبت شود.
10. ادعای ظرفیت ۱۵۰۰ کاربر تا زمان Load Test از README حذف یا با برچسب Target مشخص شود.

۱۵. نظر نهایی Auditor

این پروژه **قابلیت تبدیل شدن به محصول دانش‌بنیان را دارد**، چون داده تخصصی فارسی، Pipeline جدید وب‌سایت، فرایند بازبینی Transcript و مسئله واقعی Citation/Safety در حوزه مالی می‌توانند پایه دانش فنی قابل دفاع باشند.

اما در وضعیت Commit بررسی‌شده:

- محصول سه‌منبعی هنوز ساخته نشده است.
- RAG موجود بیشتر یک Demo Dense RAG است.
- معیارهای علمی کیفیت و Safety اثبات نشده‌اند.
- پرونده Reproducibility، R&D و حقوق داده ناقص است.

پس جمع‌بندی حرفه‌ای این است:

> **مسیر درست است، ولی ادامه مسیر باید از «جمع‌آوری داده و تکمیل Notebook» به «مهندسی محصول قابل اندازه‌گیری، قابل استناد، قابل بازتولید و ایمن» تغییر کند.**

اولویت صحیح بعدی، Embedding کردن سریع همه داده‌ها نیست. ابتدا باید Manifest، Stable IDs، Common Schema کتاب/ویدیو، Deduplication، Lineage و Golden Dataset تکمیل شود. سپس Retrieval و Generation روی Dataset نسخه‌دار ساخته و با Benchmark مقایسه شوند.

ضمیمه A — مسیر اجرایی پیشنهادی ۱۲ مرحله‌ای

1. Freeze و Tag رسمی Demo قدیمی.

2. تعریف Contract و ID policy.
3. Book Manifest و canonicalization نسخه‌ها.
4. Video Manifest و timestamp recovery/segmentation.
5. انتقال Website Notebook به Package/CLI.
6. Unified normalized documents و Quality Gate.
7. Source-aware chunking و Dataset Release v1.
8. Dense/BM25 baselines و Golden Retrieval set.
9. Hybrid + Reranker + Context compiler.
10. Grounded generation + claim citations + safety.
11. Regression/Load/Security tests و Observability.
12. Pilot، R&D dossier و آماده‌سازی پرونده ارزیابی.

ضمیمه B — وضعیت Production Readiness

جزء	Demo	Production Ready
Website ingestion	بله	خیر؛ Notebookمحور و Artifact غیرقابل دسترس
Book ingestion	خیر	خیر
Video ingestion	داده حاضر است	خیر
Unified dataset	خیر	خیر
Dense retrieval	بله	خیر
Hybrid/rerank	خیر	خیر
Citation	نمایش Source	خیر؛ Claim-level نیست
Evaluation	Smoke test	خیر
Streamlit UI	بله	خیر
Tests/CI/Deployment	خیر	خیر

ضمیمه C — اسناد Repository مشاهده‌شده

- README شاخه rag-phase2 — https://github.com/Shahbazi-Amir/RAG_finance/blob/rag-phase2/README.md
- Website Ingestion V2 Notebook — https://github.com/Shahbazi-Amir/RAG_finance/blob/rag-phase2/notebooks/phase2/01_website_ingestion.ipynb
- Website Manifest v1 — https://github.com/Shahbazi-Amir/RAG_finance/blob/rag-phase2/data/phase2/manifests/website_manifest_v1.json
- RAG Pipeline — https://github.com/Shahbazi-Amir/RAG_finance/blob/rag-phase2/src/pipeline/rag_pipeline.py
- Qdrant Retriever — https://github.com/Shahbazi-Amir/RAG_finance/blob/rag-phase2/src/retrieval/qdrant_retriever.py
- Evaluation Notebook — https://github.com/Shahbazi-Amir/RAG_finance/blob/rag-phase2/notebooks/10_evaluation.ipynb