نقشه کلان چهار فاز RAG_finance

از Demo تا RAG حرفه‌ای، لانچ چندکاربره و مربی شخصی سواد مالی

Repository	Shahbazi-Amir/RAG_finance
Branch مبنا	rag-phase2
Commit ممیزی	96c0f0c7d09f4bff107ed71664a0c57ed09f3214
تاریخ نسخه	۲۱ اوت ۲۰۲۶
دامنه	فازهای ۱ تا ۴ و قرارداد تحویل بین آن‌ها

۱. تعریف محصول نهایی

محصول نهایی سه کار متفاوت را با مرز روشن انجام می‌دهد:

- **دانش معتبر:** پاسخ به پرسش‌های سواد مالی فقط با شواهد Corpus اختصاصی.
- **آموزش هدفمند:** تشخیص سطح، شکاف دانشی و پیشنهاد محتوای مناسب.
- **مربیگری عملی:** تبدیل آموزش به هدف، اقدام کوچک، پیگیری و ارزیابی مجدد.

محصول در نسخه پایه «مشاور خریدوفروش دارایی» نیست. توصیه سرمایه‌گذاری شخصی، پیش‌بینی بازار و تصمیم مالی پرریسک باید خارج از Policy باشد یا به انسان/مرجع مجاز ارجاع شود.

۲. چرا کاربر باید این محصول را به AI عمومی ترجیح دهد؟

مزیت	رفتار قابل مشاهده در محصول
اعتبار صاحب دانش	هر پاسخ به مقاله، کتاب یا دقیقه مشخص از محتوای مؤلف متصل است
پاسخ قابل دفاع	هر ادعای واقعی Claim-level Citation و Evidence دارد
تشخیص نبود پاسخ	سیستم در نبود شاهد، سؤال روشن‌کننده می‌پرسد یا Abstain می‌کند
روش آموزشی منسجم	Taxonomy و مسیر یادگیری از روش و محتوای مؤلف ساخته می‌شود
کاربرد شخصی ایمن	قواعد و ماشین‌حساب‌های نسخه‌دار از داده ساخت‌یافته استفاده می‌کنند
رشد قابل اندازه‌گیری	آزمون قبل/بعد، اقدام‌ها، Check-in و تغییر امتیاز ثبت می‌شود
شفافیت	کاربر می‌بیند پاسخ از کجا آمده، چه داده‌ای استفاده شده و محدودیت چیست

۳. معماری کلان قابلیت‌ها

مالکیت و منابع دانش ↓ فاز ۲: Knowledge & RAG Core ↓ فاز ۳: Web Platform & Production Launch ↓ فاز ۴: Assessment + Learning + Planning + Admin ↓ نتیجه: رشد قابل سنجش سواد و سلامت مالی

در سطح محصول، چهار موتور مستقل اما هماهنگ وجود دارد:

1. **RAG Engine:** پاسخ مستند از منابع اختصاصی.
2. **Assessment Engine:** آزمون و امتیازدهی قطعی و نسخه‌دار.
3. **Planning Engine:** قواعد، ماشین‌حساب‌ها و برنامه اقدام.
4. **Conversation Engine:** گفت‌وگو، توضیح و هدایت کاربر بدون تغییر خودسرانه محاسبات.

۴. نقشه چهار فاز

فاز	هدف	خروجی نهایی	وضعیت بر اساس فایل‌های پروژه
فاز ۱	اثبات امکان RAG	Demo کامل Website → Qdrant → Answer → Streamlit	انجام‌شده؛ Baseline
فاز ۲	مهندسی دانش و RAG حرفه‌ای	RAG Core سه‌منبعی، نسخه‌دار، قابل استناد و Benchmark	فاز اجرایی جاری
فاز ۳	دیپلوی و لانچ روی سایت	Web/PWA چندکاربره با DB، امنیت، عملیات و چت عمومی	پس از Gate فاز ۲
فاز ۴	مشاور/مربی مالی و پنل گسترده	Assessment، پروفایل، مسیر، اقدام، پیشرفت و Admin	پس از پایداری فاز ۳

۵. فاز ۱ - Baseline و میراث قابل استفاده

دارایی‌های اثبات‌شده فاز ۱:

- ۷۶ مقاله نویسنده، ۱۶۸ Chunk و Embeddingهای ۳۰۷۲بعدی.
- Qdrant Local، Dense Retrieval و Qwen3-30B-A3B.
- Streamlit، Cache، تاریخچه JSON/SQLite و Evaluation ده‌سؤالی.
- ساختار ماژولار اولیه در src.

فاز ۱ نباید توسعه پیدا کند؛ باید Baseline، Tag و به‌عنوان مرجع مقایسه فریز شود. محدودیت‌های Dense-only، Character Chunking، Evaluation کوچک و Citation سطح Source باید در گزارش Baseline ثبت شوند.

۶. فاز ۲ - Knowledge & RAG Core

هدف

تبدیل سه خانواده منبع به Dataset قابل ردیابی و ساخت موتور پاسخ مستند، ایمن و قابل ارزیابی.

سه خانواده منبع

- **Website:** مقاله‌های مستقیم مؤلف و مقاله‌های تولیدشده زیر نظر سردبیری او.
- **Books:** کتاب، مقاله بلند و نوشته‌های تألیفی مؤلف؛ با تفکیک Work/Edition.
- **Video/Audio:** تدریس، آموزش، مصاحبه و برنامه تلویزیونی تبدیل‌شده به Transcript.

خروجی

- Registry حقوق و منشأ محتوا.
- Pipeline مستقل و تکرارپذیر برای هر منبع.
- Dataset/Index releases، Lineage، Stable IDs، Common Schema.
- Hybrid Retrieval، Source-aware Chunking و Reranker فقط در صورت اثبات.
- Answerability، Claim-level Citation، Context Builder و Safety.
- Regression، Benchmark، Golden Dataset و System/Dataset/Model cards.

Gate

پاسخ هر سؤال از Dataset و Index نسخه‌دار تا Document، Chunk، Claim و Raw source قابل ردیابی باشد و نتیجه Benchmark از محیط تمیز تکرار شود.

۷. فاز ۳ - Platform & Launch

هدف

عرضه واقعی RAG فاز ۲ روی سایت برای کاربران ثبت‌شده، با ذخیره امن گفت‌وگو و امکان عملیات پایدار.

خروجی

- Web/PWA واکنش‌گرا، FastAPI و PostgreSQL.
- Auth/session، consent، tenant/user isolation و RLS.
- Conversation، message، citation، retrieval/model run و feedback.
- Qdrant پایدار برای دانش عمومی؛ Redis و Object Storage.
- Dockerized deployment، reverse proxy، TLS، backup/restore و CI/CD.
- Staging، Production، observability، rate limit، cost guard و incident runbook.

Gate

کاربر واقعی بتواند وارد شود، چت کند، Citation را باز کند، تاریخچه خود را ببیند و هیچ داده‌ای بین کاربران نشت نکند؛ Release و rollback و restore آزمایش شده باشد.

۸. فاز ۴ - مربی سواد مالی و پنل مدیریت

هدف

عبور از «پرسش‌وپاسخ» به چرخه رشد:

Assess → Explain → Plan → Act → Check-in → Reassess

خروجی کاربر

- Onboarding و رضایت داده.
- آزمون سواد و سلامت مالی، سطح‌بندی و نمایش شکاف‌ها.
- پروفایل اختیاری درآمد، هزینه، بدهی، پس‌انداز و هدف.
- مسیر یادگیری و محتوای منتخب از سه منبع.
- برنامه اقدام دوره‌ای با قواعد شفاف.
- Check-in، یادآوری، بازآزمون و نمودار پیشرفت.
- توضیح منبع، Confidence components و ارجاع موارد حساس.

خروجی پنل مدیریت

- مدیریت Taxonomy، محتوا، Release و Rights.
- مدیریت سؤال/آزمون/Scoring version.
- مدیریت قواعد، Prompt، Policy و Feature flag.
- مشاهده کیفیت Retrieval/Citation/Safety و صف بازبینی.
- پشتیبانی کاربر با دسترسی محدود و Auditشده.
- گزارش رشد آموزشی و سلامت سرویس.

Gate

در پایلوت کنترل‌شده، مسیر کامل از Assessment تا Reassessment کار کند و اثر با KPIهای رفتاری و آموزشی سنجیده شود؛ خروجی عددی حساس فقط از Rules/Calculators نسخه‌دار تولید شود.

۹. قرارداد تحویل بین فازها

تحویل	اجزای الزامی
فاز ۱ → ۲	Tag، Baseline، Dataset/Model/Prompt config و Known limitations
فاز ۲ → ۳	RAG API contract، Dataset/Index IDs، Citation schema، Policy و Eval report
فاز ۳ → ۴	Auth/consent، user isolation، event model، conversation API و operational SLOs
فاز ۴ → بهره‌برداری	Assessment/Rules versions، pilot report، safety review و product KPI dashboard

۱۰. مسیر دانش فنی و دانش‌بنیان

پرونده فنی باید در طول کار ساخته شود، نه در پایان:

محور دفاع	شواهد لازم
مهندسی داده اختصاصی	سه Pipeline، Schema، Lineage، Rights و Quality reports
مهندسی بازیابی	Baseline، Hybrid/Reranker experiments و Ablation
اعتماد و استناد	Claim citation، verifier، answerability و conflict handling
فارسی و حوزه مالی	Normalizer، Taxonomy، آزمون و Policy تخصصی
محصول هوشمند	Assessment/Planning engines و جداسازی منطق قطعی از LLM
اثر	Golden tests، pilot، pre/post assessment و action completion
بازتولیدپذیری	ADR، experiment registry، CI، releases و runbooks

طبق آیین‌نامه، تعیین حوزه‌ها و معیارهای تشخیص مصادیق در اختیار کارگروه مربوط است و معیارها می‌توانند تغییر کنند؛ بنابراین این نقشه تضمین تأیید رسمی نیست. مرجع حقوقی: https://qavanin.ir/Law/TreeText/?IDS=7646595681372737421

۱۱. قواعد مشترک اجرای پروژه

- هر Task باید Documentation، Acceptance، Test، Code و Commit مشخص داشته باشد.
- Notebook برای Exploration است؛ مسیر اصلی باید Package/CLI/API باشد.
- Raw data تغییرناپذیر و هر Release دارای Hash باشد.
- هیچ تصمیم معماری بدون ADR و هیچ انتخاب مدل بدون Benchmark نباشد.
- هیچ PII، Secret یا Test set محرمانه وارد Git نشود.
- هر Claim پاسخ باید Citation معتبر یا دلیل Abstention داشته باشد.
- اطلاعات شخصی کاربر در PostgreSQL باقی بماند و بدون نیاز روشن وارد Vector DB نشود.
- تغییرات Policy، Prompt، Index، Dataset و Rules باید Versioned و قابل Rollback باشند.

۱۲. شاخص نهایی موفقیت

معیار موفقیت، تعداد پیام نیست:

- کیفیت Citation و Grounded answer.
- تشخیص صحیح سؤال بی‌پاسخ و پرریسک.
- تکمیل آزمون و مسیر یادگیری.

- انجام اقدام پیشنهادشده.
- بهبود آزمون مجدد و شاخص‌های تعریف‌شده.
- حفظ حریم خصوصی و نبود نشت بین کاربران.
- هزینه و پایداری قابل کنترل.

۱۳. تصمیم نهایی

مسیر چهارمرحله‌ای درست است، به شرط آنکه:

1. فاز ۲ با RAG Core واقعی و Benchmark بسته شود.
2. فاز ۳ فقط Demo آنلاین نباشد و الزامات محصول چندکاربره را پاس کند.
3. فاز ۴ چت را به Assessment، Rules، Action و Outcome متصل کند.
4. مستندات دانش فنی در هر Gate هم‌زمان تولید شوند.

با این مرزبندی، پروژه دلیل روشنی برای انتخاب شدن به‌جای AI عمومی دارد و از نظر فنی قابلیت تبدیل شدن به محصول قابل دفاع را خواهد داشت.