نقشه راه اجرایی ماژولار فاز ۲

پروژه RAG_finance

نسخه رسمی کارفرما و ارزیابی فنی؛ شامل ۲۴ نوت‌بوک مستقل، انتساب صحیح محتوا، Gateهای پذیرش و شواهد دانش فنی

نوع سند	راهنمای اجرایی و قرارداد فنی فاز ۲
دامنه	داده چندمنبعی، مهندسی دانش، بازیابی، استناد و ارزیابی
ساختار	۲۴ نوت‌بوک مستقل با ورودی، خروجی و Gate نسخه‌دار
حاکمیت محتوا	تفکیک تألیف مستقیم از نویسندگی زیر نظر سردبیری
تحویل	Release بازتولیدپذیر و قرارداد آماده اتصال به فاز ۳

این سند برنامه توسعه نیست؛ دستور اجرای کنترل‌شده فاز ۲ و مبنای ثبت دانش فنی است.

نسخه بازنگری‌شده بر مبنای نوت‌بوک‌های مستقل و انتساب دقیق محتوا Repository: Shahbazi-Amir/RAG_finance **Branch بررسی‌شده:** rag-phase2 **Commit مبنا:** 96c0f0c7d09f4bff107ed71664a0c57ed09f3214 **تاریخ سند:** ۲۱ اوت ۲۰۲۶ **مخاطب:** کارفرما، تیم فنی، مدیر محصول و ارزیاب فنی **وضعیت Repository:** این سند فقط حاصل بازرسی است و هیچ تغییری در مخزن ایجاد نکرده است.

۱. تصمیم اصلاحی اصلی

فاز ۲ مانند فاز ۱ از چند نوت‌بوک مستقل تشکیل می‌شود. هر مرحله فایل .ipynb جداگانه دارد و یک خروجی نسخه‌دار تولید می‌کند که ورودی مرحله بعد است.

این تصمیم سه دلیل دارد:

1. اگر یک مرحله شکست بخورد، لازم نیست کل Pipeline دوباره اجرا شود.

2. هر بخش به‌صورت مستقل قابل آموزش، تست، بازبینی و انتقال به نیروی دیگر است.

3. شواهد دانش فنی هر مرحله جداگانه ثبت می‌شود و برای ارزیابی فنی قابل دفاع‌تر است.

نوت‌بوک مستقل به معنی کد تکراری نیست. توابع پایدار در src/phase2/ قرار می‌گیرند و نوت‌بوک‌ها آن‌ها را import می‌کنند. نوت‌بوک محل توضیح فارسی، اجرای آزمایش، نمایش نتیجه، تصمیم‌گیری و ثبت شواهد است.

۲. نتیجه بازرسی الگوی فاز ۱

در پوشه notebooks/ فاز ۱ مراحل به فایل‌های مستقل تقسیم شده‌اند:

01_website_ingestion.ipynb
02_preprocessing.ipynb
03_chunking.ipynb
04_embeddings.ipynb
04_embeddings_arvan.ipynb
05_vectorstore.ipynb
06_retrieval.ipynb
07_generation.ipynb
08_rag_pipeline.ipynb
09_final_rag_demo.ipynb
10_evaluation.ipynb
11_apps.ipynb

این الگو برای فاز ۲ حفظ می‌شود، ولی ضعف‌های فاز ۱ تکرار نمی‌شوند. در تعدادی از نوت‌بوک‌های فاز ۱ سلول اجرانشده یا Error Output باقی مانده است. بنابراین در فاز ۲ هر نوت‌بوک باید از Kernel پاک اجرا شود و با Error صفر تحویل شود.

۳. وضعیت بخش سایت فاز ۲

فایل موجود:

notebooks/phase2/01_website_ingestion.ipynb

شواهد قابل مشاهده در فایل:

- ۱۷۵ سلول شامل ۸۲ سلول Code و ۹۳ سلول Markdown؛
- تمام ۸۲ سلول Code دارای Execution Count متوالی هستند؛
- Error Output ثبت‌شده وجود ندارد؛
- ۵۲۹ مقاله کشف، Crawl، اعتبارسنجی و استخراج گزارش شده‌اند؛
- ۷۶ مقاله primary_author و ۴۵۳ مقاله supervised گزارش شده‌اند؛
- عنوان، متن، نویسنده و Raw Hash خالی در گزارش نهایی صفر است.

اما برای بستن Gate حرفه‌ای کافی نیست:

- Raw، Interim و Reportهای فاز ۲ در .gitignore قرار دارند؛ بنابراین وجود Snapshot محلی از روی Git اثبات نمی‌شود.
- در Manifest ثبت‌شده، ۴۵۳ مقدار author خالی و وضعیت همه رکوردها discovered است.
- عدد ۵۲۹ در گزارش پایانی Hard-code شده است.
- Validationها بیشتر print هستند و assert شکست‌پذیر ندارند.
- کنترل Near-duplicate، Boilerplate و بازبینی انسانی نمونه‌ای کامل نیست.
- چند تابع در طول نوت‌بوک بازتعریف شده‌اند و نسخه مرجع واحد ندارند.

تصمیم: سایت از صفر تکرار نمی‌شود. نوت‌بوک موجود Freeze می‌شود و نوت‌بوک مستقل website_acceptance.ipynb_02 برای ممیزی، Repair و پذیرش آن اجرا می‌شود. Crawl کامل فقط زمانی مجاز است که Raw محلی مفقود یا نامعتبر باشد یا Snapshot جدید عمداً ساخته شود.

۳.۱. قاعده قطعی مالکیت و نقش محتوای مقالات

مقالات سایت یک گروه یکسان نیستند و نباید در Dataset یا پاسخ نهایی به یک شکل معرفی شوند:

1. مقاله تألیف مستقیم مؤلف مرجع: متن به نام خود مؤلف منتشر شده و می‌تواند به‌عنوان بیان مستقیم او معرفی شود؛ البته فقط وقتی Byline یا مدرک منبع این انتساب را تأیید کند.

2. مقاله نویسنده دیگر زیر نظر سردبیری مؤلف مرجع: نویسنده واقعی مقاله باید حفظ شود و نقش مؤلف مرجع فقط «سردبیر/ناظر علمی» ثبت شود. این مقاله نباید در پاسخ به‌عنوان نوشته مستقیم مؤلف معرفی شود.

3. وضعیت نامشخص: اگر Byline یا مدرک نقش سردبیری کامل نیست، رکورد با attribution_status=pending_review قرنطینه می‌شود و هیچ نامی حدس زده نمی‌شود.

فیلدهای اجباری Website Schema:

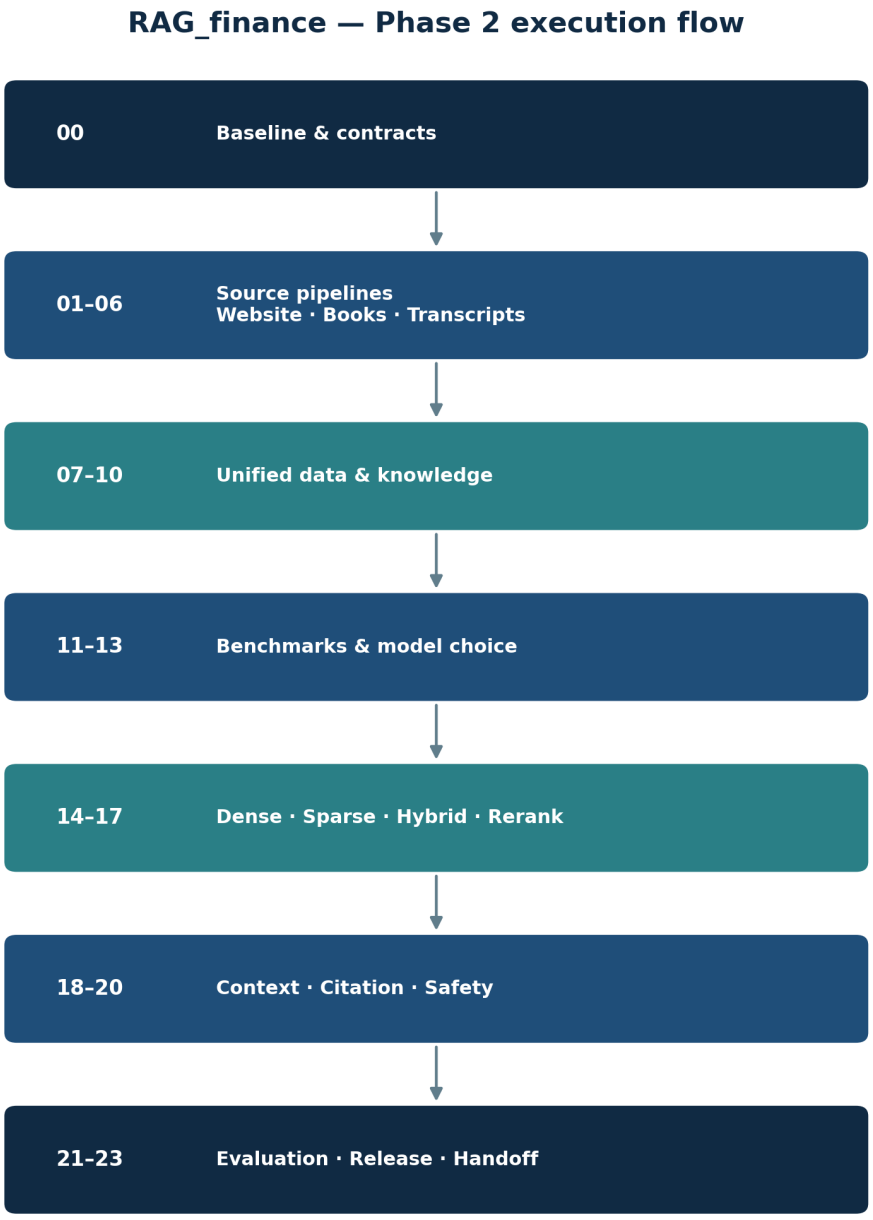
credited_author_name
reference_expert_name
editorial_supervisor_name
content_authority_type = direct_author | editorial_supervision | unknown_pending_review
byline_raw
editorial_credit_raw
authorship_assertion_source
attribution_status = verified | pending_review | rejected

نگاشت مقادیر فعلی primary_author و supervised فقط بعد از تطبیق با Byline و شواهد صفحه انجام می‌شود. تعدادهای گزارش‌شده فعلی، جایگزین تأیید انتساب نیستند.

قاعده استفاده در RAG:

- برای پرسش‌هایی مانند «نظر خود مؤلف چیست؟» فقط کتاب تألیفی، گفتار مستقیم مؤلف و مقاله direct_author مجاز است.
- برای پرسش آموزشی عمومی، مقاله‌های editorial_supervision نیز قابل استفاده‌اند، اما Citation باید نام نویسنده واقعی و نقش سردبیری را جداگانه نمایش دهد.
- رتبه‌بندی نباید نقش سردبیری را به‌طور پنهان معادل نویسندگی مستقیم کند.
- اختلاف میان محتوای تألیف مستقیم و محتوای سردبیری باید در Context با authority_type قابل تشخیص باشد.

۴. فلوچارت کل اجرای فاز ۲



شکل ۱ — جریان اجرایی فاز ۲ از *Baseline* تا تحویل فاز ۳

۵. قاعده استقلال نوت‌بوک‌ها

هر نوت‌بوک باید شرایط زیر را رعایت کند:

- از متغیر داخل حافظه نوت‌بوک قبلی استفاده نکند.
- ورودی را فقط از Artifact ذخیره‌شده و نسخه‌دار بخواند.
- در ابتدای اجرا، Schema، Version و Hash ورودی را کنترل کند.
- خروجی را ابتدا موقت بسازد، اعتبارسنجی کند و سپس نهایی کند.
- در پایان، checkpoint.json و گزارش Markdown/JSON مستقل تولید کند.
- از Kernel پاک و با Restart & Run All اجرا شود.

- سلول Code اجرانشده و Error Output نداشته باشد.
- اعداد، مسیر شخصی، Timestamp و Metadata را حدس نزند.
- بدون اجازه صریح Commit یا Push نکند.

الگوی نام‌گذاری سلول‌های هر نوت‌بوک:

```
NB<شماره>-C01, NB-<شماره>-C02, ...
```

هر نوت‌بوک باید با این چهار بخش توضیحی آغاز شود:

1. این مرحله چه کاری انجام می‌دهد؟
2. چرا برای محصول و دانش فنی لازم است؟
3. ورودی و خروجی دقیق چیست؟
4. در چه شرایطی مرحله PASS یا FAIL می‌شود؟

۶. ساختار نهایی نوت‌بوک‌های فاز ۲

```
notebooks/phase2/
00_environment_and_baseline.ipynb
01_website_ingestion.ipynb
02_website_acceptance.ipynb
03_book_inventory.ipynb
04_book_ingestion.ipynb
05_transcript_inventory.ipynb
06_transcript_ingestion.ipynb
07_unified_schema_and_lineage.ipynb
08_persian_normalization.ipynb
09_deduplication_and_quality.ipynb
10_taxonomy_and_knowledge_engineering.ipynb
11_chunking_benchmark.ipynb
12_golden_dataset.ipynb
13_embedding_benchmark.ipynb
14_dense_index.ipynb
15_sparse_index.ipynb
16_hybrid_retrieval.ipynb
17_reranking.ipynb
18_context_builder.ipynb
19_generation_and_citation.ipynb
20_answerability_safety_confidence.ipynb
21_evaluation_and_ablation.ipynb
22_release_and_reproducibility.ipynb
23_phase3_handoff.ipynb
```

۷. دستور اجرایی تفصیلی هر نوت‌بوک

Notebook 00 — 00_environment_and_baseline.ipynb

توضیح برای کارفرما

این مرحله مانند صورت‌جلسه شروع پروژه است. قبل از پردازش داده باید معلوم باشد کد روی کدام نسخه، با چه کتابخانه‌ها، چه تنظیمات و چه داده‌ای اجرا شده است. بدون این مرحله اگر نتیجه تغییر کند، نمی‌توان علت تغییر را پیدا کرد یا همان نتیجه را دوباره ساخت.

هدف فنی

ثبت Environment، Freeze فاز ۱، تعیین شناسه Release و ساخت قرارداد مشترک اجرای همه نوت‌بوک‌ها.

ورودی

- Repository و Branch فعلی؛
- Artifactها و گزارش ارزیابی فاز ۱؛
- فایل‌های Configuration و متغیرهای محیطی بدون نمایش Secret.

سلول‌ها

سلول	کار	دلیل
NB00-C01	معرفی دامنه فاز ۲ Markdown	جلوگیری از ورود Deployment و پنل به فاز ۲
NB00-C02	تشخیص Repo Root، Branch و Commit	حذف مسیرهای شخصی و ثبت نسخه کد
NB00-C03	نمایش نسخه Python و Packageها	بازتولیدپذیری محیط
NB00-C04	بررسی Secret فقط از نظر وجود	جلوگیری از افشای کلیدها
NB00-C05	تنظیم Seed و timezone UTC	کاهش تغییرپذیری آزمایش
NB00-C06	ساخت run_id و release_candidate_id	اتصال گزارش‌ها به یک اجرای مشخص
NB00-C07	موجودی Artifactهای فاز ۱	تثبیت Baseline مقایسه
NB00-C08	ثبت محدودیت‌های فاز ۱	مشخص‌کردن مسئله‌ای که فاز ۲ حل می‌کند
NB00-C09	Hash تنظیمات و Artifactهای Baseline	اثبات عدم تغییر ورودی
NB00-C10	Capability Gate و Assertها	توقف سریع در محیط ناقص

خروجی

artifacts/phase2/run_context.json
reports/phase2/baseline/phase1_baseline.json
reports/phase2/baseline/known_limitations.md
artifacts/phase2/checkpoints/00_environment.json

Gate

Branch و Commit مشخص، مسیرها قابل دسترسی، Secret لازم موجود، Hashها ثبت و فایل فاز ۱ تغییرنکرده باشد.

شاهد دانش فنی

Environment manifest، Baseline قابل تکرار، فهرست محدودیت‌ها و روش کنترل تغییرپذیری.

Notebook 01 — 01_website_ingestion.ipynb

توضیح برای کارفرما

این نوت‌بوک نسخه خام و قابل ردیابی همه مقالات سایت را ایجاد کرده است. ارزش آن فقط در «دانلود متن» نیست؛ باید بتوان نشان داد هر متن دقیقاً از کدام URL، در چه زمان و با چه Hash دریافت شده است.

تصمیم درباره فایل موجود

فایل فعلی از ابتدا بازنویسی نمی‌شود. به‌عنوان Snapshot اجرایی حفظ می‌شود. اصلاحات عمومی فقط در صورتی روی آن انجام می‌شود که اجرای پذیرش Notebook 02 ثابت کند Artifact لازم مفقود است.

اجزای موجود

- کشف صفحه‌بندی‌شده مقالات؛
- ساخت Stable ID؛
- شناسایی ۷۶ مقاله مؤلف؛
- Crawl دارای Retry و Resume؛
- Raw Hash و بررسی ساختار HTML؛
- استخراج عنوان، متن، نویسنده، Tag و آمار؛
- نرمال‌سازی اولیه؛
- گزارش ۵۲۹ مقاله.

مواردی که نباید دوباره انجام شوند

- Crawl کامل بدون بررسی Raw موجود؛
- تغییر Stable IDهای فعلی؛
- حذف Raw قدیمی؛
- تبدیل ۴۵۳ مقاله سردبیری به «تألیف مستقیم»؛
- حدس مالکیت یا نویسنده مفقود.

خروجی مورد انتظار برای مرحله بعد

```
data/phase2/manifests/website_manifest_v1.json
data/phase2/raw/website/<article_id>/article.html
data/phase2/raw/website/<article_id>/source.json
data/phase2/interim/website_extracted_v2.json
reports/phase2/data_quality/website_extraction_v2.json
reports/phase2/ingestion/website_ingestion_v2.json
```

شاهد دانش فنی

Discovery بدون Hard-code تعداد، Content-origin classification، Raw integrity، Resume crawl و Extraction report.

Notebook 02 — 02_website_acceptance.ipynb

توضیح برای کارفرما

در این مرحله خروجی سایت مانند یک محموله تحویلی بازرسی می‌شود. گزارش قبلی می‌گوید ۵۲۹ مقاله داریم؛ این نوت‌بوک بررسی می‌کند آیا واقعاً تمام فایل‌ها موجود، سالم، غیرتکراری و قابل استناد هستند یا خیر.

هدف فنی

تبدیل Website Ingestion موجود از «اجرای موفق در نوت‌بوک» به Dataset پذیرفته‌شده و نسخه‌دار.

سلول‌ها

سلول	کار	دلیل
NB02-C01	بارگذاری Manifest و Schema validation	بررسی قرارداد داده

سلول	کار	دلیل
NB02-C02	موجودی واقعی Raw/Interim/Report	تشخیص فایل مفقود
NB02-C03	کنترل Hash تمام HTMLها	اثبات عدم خرابی Raw
NB02-C04	تطبیق ۱:۱ Manifest، Raw و Extracted	جلوگیری از رکورد گمشده یا اضافی
NB02-C05	ساخت Repair Queue	محدودکردن Crawl به موارد لازم
NB02-C06	Repair incremental با Retry/Backoff	تکمیل بدون دانلود مجدد همه سایت
NB02-C07	انتقال Extractor نهایی به ماژول مرجع	حذف چند تعریف متفاوت
NB02-C08	Fixture و Regression Test ساختار HTML	تشخیص تغییر قالب سایت
NB02-C09	استخراج مجدد از Raw پذیرفته‌شده	تولید خروجی قطعی
NB02-C10	کنترل HTML leakage و Boilerplate	جلوگیری از ورود منو و اجزای سایت
NB02-C11	Exact/Near-duplicate و Outlier	کنترل کیفیت محتوایی
NB02-C12	استخراج Byline خام، نویسنده واقعی و نقش سردبیری	جلوگیری از انتساب مقاله دیگران به مؤلف مرجع
NB02-C13	ساخت نگاشت direct_author/ editorial_supervision/pending_review با مدرک	تبدیل نقش محتوایی به Metadata قابل دفاع
NB02-C14	نمونه‌گیری طبقه‌بندی‌شده از هر دو گروه محتوایی	کنترل انسانی استخراج و انتساب
NB02-C15	ثبت نتیجه بازبینی انسانی و Evidence URL/ Selector	شاهد مستقل از کد
NB02-C16	ساخت Manifest v2 پویا	حذف عدد Hard-code و تکمیل وضعیت‌ها
NB02-C17	Assertهای انتساب، Lineage و Checkpoint	Gate واقعی

خروجی

data/phase2/manifests/website_manifest_v2.jsonl
data/phase2/interim/website_extracted_v3.jsonl
reports/phase2/data_quality/website_acceptance_report.json
reports/phase2/data_quality/website_manual_review.csv
artifacts/phase2/checkpoints/02_website_acceptance.json

Gate

Stable ID تکراری صفر، Broken hash صفر، Required field خالی صفر، Lineage شکسته صفر، انتساب بدون مدرک صفر و بازبینی انسانی هر دو گروه محتوایی تأییدشده باشد.

شاهد دانش فنی

Manifest versioning، Failure analysis، Sampling design، Regression fixture، Incremental update و Data lineage.

Notebook 03 — 03_book_inventory.ipynb

توضیح برای کارفرما

وجود چند فایل Word به معنی وجود چند کتاب مستقل نیست. ممکن است دو فایل نسخه متفاوت یک اثر باشند. اگر هر دو بدون تشخیص وارد RAG شوند، یک مطلب چند بار بازیابی می‌شود و پاسخ به شکل مصنوعی به آن منبع وزن بیشتری می‌دهد.

وضعیت فعلی

هفت فایل DOCX در data/books/ وجود دارد. نام‌ها احتمال چند نسخه موازی را نشان می‌دهد، اما تشخیص نهایی فقط بعد از Hash و مقایسه متن انجام می‌شود.

سلول‌ها

سلول	کار	دلیل
NB03-C01	فهرست فایل، حجم و SHA-256	ثبت Raw inventory
NB03-C02	استخراج Core Properties و آمار پاراگراف/جدول	شناخت ساختار هر فایل
NB03-C03	استخراج متن آزمایشی و Fingerprint	مقایسه نسخه‌ها
NB03-C04	Exact و Near-duplicate analysis	یافتن نسخه‌های موازی
NB03-C05	ساخت جدول Work/Edition	تفکیک اثر از نسخه فایل
NB03-C06	ثبت author، rights و publication status	Attribution و مجوز
NB03-C07	تصمیم انسانی درباره Canonical Edition	جلوگیری از انتخاب خودکار اشتباه
NB03-C08	Assert یک Canonical Edition برای هر Work	Gate موجودی

Citation کتاب

فایل‌های فعلی DOCX صفحه ثابت ندارند. Citation قابل دفاع آن‌ها باید chapter/section/paragraph باشد. اگر Citation صفحه لازم است، باید PDF نهایی صفحه‌بندی‌شده اضافه و با Edition متناظر شود.

خروجی و شاهد دانش فنی

books_manifest_v1.jsonl، گزارش مقایسه Editionها، تصمیم Canonical و ADR مربوط به Citation کتاب.

Notebook 04 — 04_book_ingestion.ipynb

توضیح برای کارفرما

کتاب یک متن یک‌تکه نیست. عنوان فصل، زیرعنوان، مثال، تمرین و جدول نقش متفاوت دارند. استخراج حرفه‌ای این ساختار را نگه می‌دارد تا پاسخ بداند مطلب متعلق به کدام فصل و بخش است.

سلول‌ها

سلول	کار	دلیل
NB04-C01	خواندن Canonical Editionها	جلوگیری از ورود نسخه تکراری
NB04-C02	Parse ترتیب XML پاراگراف و جدول	حفظ ترتیب واقعی محتوا
NB04-C03	استخراج Style و Heading level	بازسازی سلسله‌مراتب فصل
NB04-C04	استخراج جدولها به Block ساخت‌یافته	جلوگیری از تخت‌شدن جدول
NB04-C05	ساخت Chapter/Section tree	Citation و Chunking ساختاری
NB04-C06	شماره پایدار Paragraph/Table	Locator قابل استناد
NB04-C07	جداسازی فهرست، Header/Footer و منابع	کنترل Boilerplate

سلول	کار	دلیل
NB04-C08	اتصال هر Block به Raw hash و Edition	Lineage
NB04-C09	کنترل Heading orphan و ترتیب	کیفیت ساختار
NB04-C10	نمونه‌گیری حداقل ۱۰ Block از هر اثر	بازبینی انسانی
NB04-C11	ساخت Artifact و گزارش	تحویل رسمی
NB04-C12	Assert و Checkpoint	Book Gate

خروجی

book_manual_review.csv، book_structure_report.json، books_extracted_v1.jsonl و Checkpoint.

شاهد دانش فنی

Table preservation، Citation locator، Edition control، Structure-aware parsing و ارزیابی نمونه‌ای.

Notebook 05 — 05_transcript_inventory.ipynb

توضیح برای کارفرما

Transcript فقط یک فایل متن نیست؛ باید معلوم باشد متن مربوط به کدام برنامه، فصل، قسمت، گوینده و منبع رسانه‌ای است. بدون این اطلاعات Citation و اعتماد کاربر ناقص می‌شود.

وضعیت فعلی

هفت مجموعه و دست‌کم ۱۸۳ فایل اپیزود Markdown مشاهده شده است. قالب Metadata، نام گویندگان و پوشش Timestamp یکسان نیست.

سلول‌ها

سلول	کار	دلیل
NB05-C01	پیمایش بازگشتی تمام فایل‌ها	موجودی کامل
NB05-C02	تفکیک Episode از README/Review	جلوگیری از ورود فایل مدیریتی
NB05-C03	استخراج /program/season/episode/title source/duration	Metadata coverage
NB05-C04	بررسی توالی Episodeها و Gapها	کشف قسمت مفقود
NB05-C05	اندازه‌گیری Speaker و Timestamp coverage	تعیین محدودیت Citation
NB05-C06	تشخیص عنوان media و Speaker عمومی	Repair queue
NB05-C07	Hash و duplicate detection	جلوگیری از تکرار
NB05-C08	تصمیم Canonical و ثبت ابهام	عدم حدس Metadata
NB05-C09	ساخت Transcript Manifest	قرارداد ورودی مرحله بعد

خروجی و شاهد دانش فنی

transcripts_manifest_v1.jsonl، Metadata gap report، Episode sequence report و Canonical decision log.

Notebook 06 — 06_transcript_ingestion.ipynb

توضیح برای کارفرما

گفت‌وگو باید طوری پردازش شود که مرز گوینده و قسمت حفظ شود. اگر جمله مجری با توضیح متخصص مخلوط شود، سیستم ممکن است یک سؤال یا نظر مجری را به‌عنوان نظر مؤلف اصلی نقل کند.

سلول‌ها

سلول	کار	دلیل
NB06-C01	Parse Markdown به Metadata/Speaker/Utterance	ساختاردهی گفتار
NB06-C02	Alias table برای نام گویندگان	یکسان‌سازی بدون حدس
NB06-C03	علامت‌گذاری Speaker مبهم	جلوگیری از Attribution اشتباه
NB06-C04	ادغام جمله‌های خرد در مرز همان گوینده	بهبود خوانایی و بازیابی
NB06-C05	تشخیص تکرار ASR و نویز	کیفیت متن
NB06-C06	حفظ Timestamp واقعی و ثبت missing	جلوگیری از Timestamp ساختگی
NB06-C07	ساخت locator اپیزود/گوینده/segment	Citation پایدار
NB06-C08	بازبینی حداقل ۲۰ اپیزود از همه مجموعه‌ها	ارزیابی انسانی
NB06-C09	ساخت Artifact و گزارش	تحویل رسمی
NB06-C10	Assert و Checkpoint	Transcript Gate

خروجی

transcript_quality_report.json، speaker_aliases_v1.json، transcripts_extracted_v1.jsonl و Checkpoint.

شاهد دانش فنی

Timestamp policy، ASR quality flags، Speaker-aware segmentation و Attribution test.

Notebook 07 — 07_unified_schema_and_lineage.ipynb

توضیح برای کارفرما

سه منبع ساختار متفاوت دارند. این مرحله آن‌ها را به یک زبان مشترک تبدیل می‌کند، بدون اینکه تفاوت منبع از بین برود. نتیجه این است که هر پاسخ را می‌توان تا فایل و محل اصلی دنبال کرد.

سلول‌ها و خروجی

1. تعریف و اعتبارسنجی document.schema.json؛
2. تبدیل Website به Common Document؛
3. تبدیل Book به Common Document؛
4. تبدیل Transcript به Common Document؛
5. ساخت document_id پایدار؛
6. اتصال raw_content_hash → source_id → document_id؛
7. کنترل Rights/Origin و جداسازی credited_author از editorial_supervisor؛
8. حفظ byline_raw، مدرک انتساب و content_authority_type؛

9. ساخت documents_unified_v1.jsonl؛

10. گزارش پوشش Lineage و Attribution؛

11. Assert Broken lineage و Invalid attribution برابر صفر.

شاهد دانش فنی

Data lineage، Stable IDs، Schema engineering و Source-aware mapping.

Notebook 08 — 08_persian_normalization.ipynb

توضیح برای کارفرما

در فارسی ممکن است «ی» و «ک»، نیم‌فاصله، ارقام و فاصله‌ها به شکل‌های مختلف ثبت شوند. برای انسان شبیه‌اند، ولی موتور جست‌وجو آن‌ها را متفاوت می‌بیند. نرمال‌سازی باعث بازیابی پایدارتر می‌شود، اما نباید معنای متن را تغییر دهد.

سلول‌ها

1. تعریف Policy روشن تغییرات مجاز؛

2. Unicode NFC و حذف BOM/soft-hyphen؛

3. یکسان‌سازی کنترل‌شده ی/ک؛

4. سیاست نیم‌فاصله و فاصله؛

5. سیاست ارقام، علائم و URL؛

6. نگهداری هم‌زمان raw_text و normalized_text؛

7. ثبت Transformation log؛

8. Unit test برای نمونه‌های فارسی و مالی؛

9. اجرای سه منبع؛

10. مقایسه آماری قبل/بعد و Assert عدم حذف غیرعادی.

شاهد دانش فنی

Normalizer نسخه‌دار فارسی، Regression corpus و گزارش اثر Transformation.

Notebook 09 — 09_deduplication_and_quality.ipynb

توضیح برای کارفرما

ممکن است یک مفهوم هم در مقاله، هم کتاب و هم مصاحبه تکرار شده باشد. تکرار همیشه بد نیست، اما باید شناخته شود تا سیستم تصور نکند سه منبع مستقل یک ادعا را تأیید کرده‌اند.

سلول‌ها

1. Exact duplicate با Content hash؛

2. Near-duplicate درون هر منبع؛

3. Cross-source similarity؛

4. تشخیص نسخه/اقتباس/تکرار بدون ادغام نویسندگان متفاوت؛

5. تعریف Source priority و Authority policy بدون حذف Lineage یا تغییر مالکیت اثر؛

6. Quality scoring بر اساس completeness و locator؛

7. Quarantine رکوردهای مسئله‌دار؛

8. ساخت Dataset پذیرفته‌شده؛

9. گزارش Dedup و Quality؛

10. Assert عدم حضور رکورد Quarantine در Release.

شاهد دانش فنی

Quality scoring، Canonical relation، Cross-source deduplication و Quarantine workflow.

Notebook 10 — 10_taxonomy_and_knowledge_engineering.ipynb

توضیح برای کارفرما

RAG حرفه‌ای فقط متن را جست‌وجو نمی‌کند؛ باید بداند محتوا درباره بودجه، درآمد، بدهی، پس‌انداز، ریسک، رفتار مالی یا هدف‌گذاری است. Taxonomy دانش مؤلف را به ساختار قابل استفاده تبدیل می‌کند.

سلول‌ها

1. تعریف Topicهای اصلی سواد مالی؛

2. تعریف Competency و prerequisite؛

3. تعریف نوع محتوا: مفهوم، مثال، تمرین، هشدار و راهکار؛

4. نگاشت Candidate اسناد به Topic؛

5. ثبت Reason و Confidence برچسب همراه content_authority_type؛

6. نمونه‌گیری و بازبینی متخصص؛

7. اصلاح Taxonomy؛

8. Freeze نسخه اول؛

9. Coverage و conflict report؛

10. Assert برچسب نامعتبر صفر.

شاهد دانش فنی

Domain taxonomy اختصاصی، Expert review، Competency model و Explainable labeling.

Notebook 11 — 11_chunking_benchmark.ipynb

توضیح برای کارفرما

متن‌ها برای جست‌وجو به قطعات کوچک تقسیم می‌شوند. قطعه خیلی کوچک معنی را ناقص می‌کند و قطعه خیلی بزرگ اطلاعات نامربوط وارد پاسخ می‌کند. اندازه و روش Chunking باید با آزمایش انتخاب شود، نه سلیقه.

Variantهای الزامی

- Structure-aware کوچک؛
- Structure-aware متوسط؛
- Parent-child؛
- روش مرجع Character-based فاز ۱ برای مقایسه.

سلول‌ها

1. ثبت Variant و Config؛
2. Chunking سایت بر اساس Heading/Paragraph؛
3. Chunking کتاب بدون عبور از Section؛
4. Chunking Transcript بدون شکستن Speaker segment؛
5. حفظ Citation locator و parent ID؛
6. آمار Token/Overlap/Tiny/Huge؛
7. تست Reconstruction و Lineage؛
8. ساخت Artifact هر Variant؛
9. گزارش مقایسه؛
10. انتخاب نهایی بعد از Retrieval benchmark.

شاهد دانش فنی

Ablation، Parent-child design، Source-aware chunking و Chunk quality metrics.

Notebook 12 — 12_golden_dataset.ipynb

توضیح برای کارفرما

بدون مجموعه سؤال استاندارد نمی‌توان گفت سیستم بهتر شده است. Golden Dataset مانند برگه امتحانی ثابت است که پاسخ صحیح و منبع مرتبط هر سؤال از قبل توسط متخصص تعیین می‌شود.

طبقات سؤال

- سؤال مستقیم از هر یک از سه منبع؛
- سؤال مفهومی و چندبخشی؛
- سؤال Cross-source؛
- سؤال دارای اصطلاح فارسی متنوع؛
- سؤال مبهم؛
- سؤال خارج از دانش موجود؛
- درخواست توصیه سرمایه‌گذاری شخصی؛
- سؤال دارای منبع متعارض.

سلول‌ها

1. تعریف Golden schema؛
2. Sampling plan براساس Topic و Source؛
3. ساخت Candidate pool؛
4. ورود سؤال و Relevant locator توسط متخصص؛
5. ثبت answerability و expected behavior؛
6. کنترل Label و Duplicate question؛

7. اندازه‌گیری توافق ارزیابان روی نمونه مشترک؛

8. جداسازی Dev/Test بدون Leakage؛

9. Freeze نسخه اول؛

10. Assert اعتبار تمام locatorها.

اندازه پیشنهادی

شروع پایلوت کوچک مجاز است، اما هدف اولیه Release حداقل ۳۰۰ سؤال است؛ تعداد نهایی بعد از ظرفیت داوری متخصص Freeze می‌شود.

شاهد دانش فنی

Benchmark اختصاصی فارسی حوزه مالی، Inter-annotator agreement، Labeling protocol و Leakage control.

Notebook 13 — 13_embedding_benchmark.ipynb

توضیح برای کارفرما

Embedding مدل تبدیل متن به بردار است. انتخاب یک مدل مشهور به‌تنهایی کافی نیست؛ باید روی سؤالات فارسی و داده واقعی همین پروژه اندازه‌گیری شود.

سلول‌ها

1. ثبت Candidate modelها و Revision؛

2. ثبت Provider، Tokenizer، Dimension و هزینه؛

3. Embed نمونه Benchmark با Cache نسخه‌دار؛

4. اجرای هر Embedding × Chunking؛

5. MRR، Recall@k و nDCG؛

6. تحلیل Website/Book/Transcript؛

7. تحلیل Queryهای کوتاه، بلند و محاوره‌ای؛

8. Latency، failure و cost؛

9. انتخاب با ADR؛

10. Freeze Embedding config.

شاهد دانش فنی

Benchmark بومی پروژه، Cost-quality trade-off و انتخاب مبتنی بر آزمایش.

Notebook 14 — 14_dense_index.ipynb

توضیح برای کارفرما

این مرحله بردارهای منتخب را در پایگاه برداری ذخیره می‌کند. هدف فقط ذخیره‌سازی نیست؛ هر بردار باید با شناسه، منبع و نسخه صحیح قابل ردیابی باشد.

سلول‌ها

1. خواندن Chunk release و Embedding config؛

2. ساخت Collection نسخه‌دار؛

3. تعریف Distance و Dimension؛

4. ساخت Payload schema؛

5. Batch upsert با Resume؛

6. Point count و ID parity؛

7. Payload/Vector spot-check؛

8. Snapshot و Restore test؛

9. ثبت Index manifest؛

10. Dense index Gate.

شاهد دانش فنی

Payload lineage، Index integrity، Idempotent indexing و Restore evidence.

Notebook 15 — 15_sparse_index.ipynb

توضیح برای کارفرما

جست‌وجوی معنایی گاهی نام، عدد یا اصطلاح دقیق را از دست می‌دهد. Sparse Search برای تطبیق واژه‌های دقیق استفاده می‌شود و مکمل Dense Search است.

سلول‌ها

1. تعریف Analyzer فارسی؛

2. سیاست Tokenization، ارقام و نیم‌فاصله؛

3. ساخت BM25/Sparse index؛

4. کنترل Document frequency؛

5. تست نام‌ها و اصطلاحات دقیق؛

6. Benchmark مستقل Sparse؛

7. Error analysis؛

8. Freeze Sparse config.

شاهد دانش فنی

Analyzer benchmark، Persian lexical retrieval و failure taxonomy.

Notebook 16 — 16_hybrid_retrieval.ipynb

توضیح برای کارفرما

Hybrid Retrieval نتایج معنایی و واژه‌ای را ترکیب می‌کند. این باعث می‌شود هم مفهوم سؤال و هم عبارت دقیق آن دیده شود.

سلول‌ها

1. Dense baseline؛

2. Sparse baseline؛

3. RRF fusion؛

4. Weighted fusion؛

5. Metadata filtering شامل منبع، نویسنده، گوینده و نوع اختیار محتوایی؛

6. Source diversity control؛

7. آزمایش Top-k و candidate depth؛

8. Slice metrics؛

9. Ablation dense/sparse/hybrid؛

10. انتخاب Config با ADR.

شاهد دانش فنی

Source-aware filtering، Retrieval optimization، Fusion experiment و Ablation report.

Notebook 17 — 17_reranking.ipynb

توضیح برای کارفرما

Retriever تعداد بیشتری نتیجه کاندید پیدا می‌کند؛ Reranker آن‌ها را با دقت بیشتر مرتب می‌کند تا بهترین شواهد به مدل پاسخ‌گو برسد.

سلول‌ها

1. ثبت Candidate rerankerها؛

2. ساخت Pairهای Query/Chunk؛

3. ارزیابی بدون Reranker؛

4. ارزیابی Candidateها؛

5. تحلیل فارسی و سه منبع؛

6. Latency/cost؛

7. تعیین candidate_k و final_k؛

8. Failure analysis؛

9. ADR انتخاب؛

10. Regression Gate.

شاهد دانش فنی

Reranker benchmark، کیفیت/هزینه، Error slices و Regression evidence.

Notebook 18 — 18_context_builder.ipynb

توضیح برای کارفرما

حتی اگر اسناد درست پیدا شوند، نحوه قرارگرفتن آن‌ها در Context مهم است. Context Builder باید تکرار را حذف، تنوع منبع را حفظ و شواهد را در بودجه محدود مدل بچیند.

سلول‌ها

1. Dedup نتایج Retrieval؛

2. محدودکردن dominance یک سند؛

3. تنوع Source/Topic؛

4. Parent expansion کنترل‌شده؛

5. Token budgeting؛

6. حفظ locator، نویسنده واقعی و نقش سردبیری کنار هر قطعه؛

7. تشخیص شواهد متعارض؛

8. Truncation tests؛

9. ساخت Context schema؛

10. Context Gate.

شاهد دانش فنی

Context packing algorithm، Diversity control، conflict flags و token-budget tests.

Notebook 19 — 19_generation_and_citation.ipynb

توضیح برای کارفرما

تفاوت این محصول با پاسخ عمومی مدل‌های زبانی در این است که هر ادعای مهم باید به بخش مشخصی از منبع متصل باشد و نقش صاحب محتوا نیز درست نمایش داده شود؛ صرفاً نمایش چند لینک در انتهای پاسخ کافی نیست.

سلول‌ها

1. تعریف Answer/Claim/Citation schema؛

2. Prompt نسخه‌دار و محدود به Context؛

3. تولید پاسخ ساخت‌یافته؛

4. شکستن پاسخ به Claim؛

5. اتصال Claim به Chunk پشتیبان؛

6. Citation verifier برای support و locator؛

7. حذف یا بازنویسی Claim بدون پشتوانه؛

8. Citation مقاله تألیف مستقیم با URL و عبارت «نویسنده: ...»؛

9. Citation مقاله سردبیری با URL، «نویسنده: ...» و «زیر نظر سردبیری: ...» به‌صورت دو نقش مستقل؛

10. Citation کتاب با Work/Chapter/Paragraph و مؤلف اثر؛

11. Citation Transcript با Program/Episode/Speaker/Segment و گوینده واقعی؛

12. تست جلوگیری از Misattribution بین نویسنده و سردبیر؛

13. Broken locator tests؛

14. Claim coverage و Attribution correctness report و Gate.

شاهد دانش فنی

Unsupported-claim control، Source-specific locator، Claim-level citation و Citation correctness benchmark.

Notebook 20 — 20_answerability_safety_confidence.ipynb

توضیح برای کارفرما

سیستم حرفه‌ای باید بداند چه زمانی پاسخ کافی ندارد و چه زمانی سؤال وارد تصمیم مالی شخصی یا سرمایه‌گذاری می‌شود. Confidence نباید عددی باشد که مدل زبانی از خودش تولید کرده است.

سلول‌ها

1. Intent classification؛
2. تشخیص سؤال آموزشی/مبهم/خارج از دامنه؛
3. Answerability از Evidence coverage؛
4. Clarification policy؛
5. Abstention policy؛
6. تفکیک آموزش مالی از توصیه سرمایه‌گذاری شخصی؛
7. Safety routing برای تصمیم پراثر؛
8. Confidence components: retrieval، citation، agreement و completeness؛
9. Confidence calibration روی Golden set؛
10. Prompt injection tests در Query و Retrieved content؛
11. Adversarial/safety cases؛
12. Safety Gate.

شاهد دانش فنی

domain safety policy، calibrated abstention، Explainable confidence و adversarial test suite.

Notebook 21 — 21_evaluation_and_ablation.ipynb

توضیح برای کارفرما

این نوت‌بوک گزارش می‌کند محصول واقعاً چقدر درست کار می‌کند و کدام جزء باعث بهبود شده است. Ablation یعنی یک جزء را موقتاً حذف کنیم تا اثر واقعی آن مشخص شود.

معیارها

- Recall@k، MRR و nDCG؛
- Groundedness و completeness؛
- Citation correctness و claim coverage؛
- Attribution correctness برای direct author، نویسنده سردبیری و گوینده؛
- No-answer precision/recall/F1؛
- Safety violation rate؛
- Latency، token، cost و failure؛
- نتایج تفکیکی Website/Book/Transcript/Topic/Question type/Authority type.

Ablationهای اجباری

- بدون Persian normalization؛
- Character chunking در برابر Structure-aware؛
- Dense-only در برابر Hybrid؛
- بدون Reranker؛
- بدون Source diversity؛
- بدون Citation verifier.

خروجی و شاهد دانش فنی

Failure cases، Error taxonomy، Ablation report، Benchmark report، مقایسه فاز ۱ و Regression Gate.

Notebook 22 — 22_release_and_reproducibility.ipynb

توضیح برای کارفرما

Release فقط یک پوشه خروجی نیست. باید دقیقاً مشخص باشد کدام داده، کد، مدل، تنظیمات و آزمون‌ها آن را ساخته‌اند و چگونه می‌توان همان نسخه را دوباره ایجاد کرد.

سلول‌ها

1. جمع‌آوری تمام Version IDها؛
2. Hash Dataset/Chunk/Index/Config؛
3. ساخت Release manifest؛
4. Data Card؛
5. Retrieval Card؛
6. Evaluation Card؛
7. Known limitations؛
8. تست Restore و بازاجرای Validate-only؛
9. پاک‌سازی Output از Secret و مسیر شخصی؛
10. کنترل Notebookها: unrun=0 و error=0؛
11. ساخت Evidence index؛
12. Final Release Gate.

شاهد دانش فنی

Test evidence، Artifact provenance، Reproducible release و Documentation package.

Notebook 23 — 23_phase3_handoff.ipynb

توضیح برای کارفرما

فاز ۳ نباید مجبور شود منطق فاز ۲ را حدس بزند. این مرحله قرارداد مشخصی می‌سازد که وب‌سایت و API بدانند چگونه سؤال بفرستند و پاسخ، Confidence، Citation، Claim و Safety decision را دریافت کنند.

سلول‌ها

1. بارگذاری Release پذیرفته‌شده فاز ۲؛
2. تعریف Request schema؛
3. تعریف Response schema؛
4. تعریف Citation object؛
5. تعریف statusهای answer/no-answer/clarification/safety؛
6. ثبت تمام Artifact versionها در پاسخ؛
7. ساخت Contract fixtures؛
8. تست backward compatibility؛
9. ساخت Sample conversations؛
10. Readiness report و Gate تحویل.

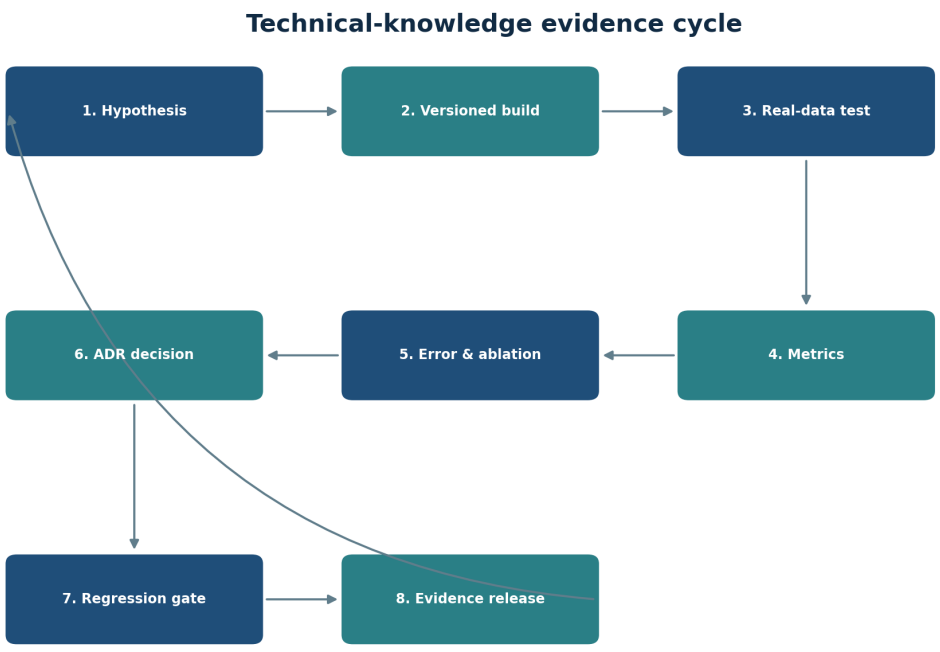
خروجی

```
artifacts/phase2/releases/<release_id>/phase3_handoff_contract.json
schemas/phase2/rag_request.schema.json
schemas/phase2/rag_response.schema.json
tests/phase2/contracts/
reports/phase2/release/phase3_readiness.md
```

شاهد دانش فنی

Versioned API contract، traceable response، contract tests و separation of concerns بین RAG و Deployment.

۸. فلوچارت چرخه اثبات دانش فنی



شکل ۲ — چرخه تولید و ثبت شواهد دانش فنی

این چرخه نشان می‌دهد ارزش فنی پروژه فقط استفاده از مدل آماده نیست. برای هر جزء، فرضیه، پیاده‌سازی، داده آزمایشی، نتیجه کمی، تحلیل شکست و تصمیم نسخه‌دار وجود دارد.

۹. ساختار ماژول‌های کد پشت نوت‌بوک‌ها

```
src/phase2/
contracts/
ids.py
schemas.py
versions.py
ingestion/
website.py
books.py
transcripts.py
normalization/
persian.py
quality/
validators.py
dedup.py
sampling.py
knowledge/
taxonomy.py
mapping.py
chunking/
website.py
books.py
transcripts.py
parent_child.py
embeddings/
registry.py
benchmark.py
retrieval/
dense.py
sparse.py
hybrid.py
reranking/
benchmark.py
generation/
context_builder.py
generator.py
citation/
claims.py
verifier.py
locators.py
attribution.py
safety/
intent.py
answerability.py
confidence.py
policy.py
evaluation/
metrics.py
runner.py
ablation.py
release/
manifest.py
evidence.py
```

Notebook ابتدا روش را توضیح می‌دهد، سپس تابع را با نمونه آزمایش می‌کند. وقتی تابع پذیرفته شد، نسخه پایدار آن در ماژول قرار می‌گیرد. این کار انتقال دانش و تست خودکار را هم‌زمان ممکن می‌کند.

۱۰. Artifactها و مسیر نسخه‌بندی

```
data/phase2/manifests/
data/phase2/raw/
data/phase2/interim/
data/phase2/processed/
data/phase2/chunks/
data/phase2/embeddings/
data/phase2/index/

schemas/phase2/
config/phase2/
reports/phase2/
artifacts/phase2/checkpoints/
artifacts/phase2/releases/<release_id>/
```

Raw و Artifactهای حجیم نباید بدون برنامه داخل Git معمولی قرار گیرند. Manifest، Schema، Config، گزارش و Pointer نسخه‌دار Commit می‌شوند و فایل‌های حجیم با DVC، Object Storage یا روش نسخه‌دار مورد تأیید پروژه نگهداری می‌شوند.

۱۱. Evidence Matrix دانش فنی

حوزه	شاهد الزامی	نوت‌بوک مسئول
Data Engineering	Manifest، Hash، Incremental update، Quality report	01 تا 09
دانش فارسی	Normalization policy و Regression corpus	08
مهندسی دانش	Taxonomy، Competency، Expert review	10
معماری چندمنبعی	Common schema و Source-specific locator	07
Retrieval Optimization	Dense/Sparse/Hybrid/Reranker benchmark	13 تا 17
Citation System	Claim-level verifier و locator tests	19
حاکمیت انتساب	Byline evidence، تفکیک نویسنده/سردبیر و Misattribution tests	02، 07، 19 و 21
کنترل توهم	Answerability، Abstention و unsupported claim tests	19 و 20
ایمنی مالی	Intent/Safety policy و adversarial tests	20
ارزیابی	Golden Dataset، Benchmark و Ablation	12 و 21
بازتولیدپذیری	Version IDs، hashes، clean rerun و restore	00 و 22
انتقال دانش	توضیح فارسی، ADR، Data/Model/Retrieval cards	همه، به‌ویژه 22

هیچ‌یک از این موارد تأیید دانش‌بنیان را تضمین نمی‌کند، اما نبود آن‌ها دفاع فنی پروژه را به «مدل آماده + Vector Database» محدود می‌کند.

۱۲. Test Suite الزامی

```
tests/phase2/unit/
test_stable_ids.py
test_website_extractor.py
test_book_extractor.py
test_transcript_parser.py
test_persian_normalization.py
test_deduplication.py
test_chunk_locators.py
test_content_attribution.py
test_confidence_components.py

tests/phase2/integration/
test_raw_to_document.py
test_document_to_chunk.py
test_chunk_to_index.py
test_query_to_citation.py

tests/phase2/regression/
test_website_html_fixtures.py
test_golden_retrieval.py
test_golden_citations.py
test_author_editor_separation.py
test_no_answer.py
test_financial_safety.py

tests/phase2/contracts/
test_phase3_request.py
test_phase3_response.py
test_version_trace.py
```

هر باگ مهم ابتدا به Fixture یا Regression Test تبدیل و سپس اصلاح می‌شود.

۱۳. معیارهای اولیه پذیرش

این اعداد Target اولیه داخلی‌اند و بعد از Baseline و ظرفیت داوری متخصص باید Freeze شوند.

معیار	Target اولیه
Required schema completeness	100%
Stable ID تکراری	0
Broken raw hash	0
Broken lineage	0
Invalid citation locator	0
مقاله با انتساب بدون مدرک در Release	0
خطای انتساب نویسنده/سردبیر در Golden set	0
Retrieval Recall@10	حداقل 0.85
Retrieval nDCG@10	حداقل 0.75
Citation correctness	حداقل 0.95
Claim citation coverage	حداقل 0.90
Unsupported critical claim	0

معیار	Target اولیه
No-answer F1	حداقل 0.85
Critical safety test pass	100%
Notebook unrun/error cells	0

۱۴. تقسیم پیشنهادی Commitها

هر نوت‌بوک و ماژول‌های همان مرحله یک Commit قابل بازبینی تشکیل دهند. داده Raw حجیم Commit نمی‌شود. نام پیشنهادی:

```
phase2: add environment and baseline gate
phase2: accept website dataset v2
phase2: register canonical book editions
phase2: add structure-aware book ingestion
phase2: register transcript inventory
phase2: add speaker-aware transcript ingestion
phase2: add unified schema and lineage
phase2: add Persian normalization
phase2: add cross-source deduplication
phase2: add financial literacy taxonomy
phase2: benchmark source-aware chunking
phase2: add golden dataset v1
phase2: benchmark embedding candidates
phase2: build dense index v2
phase2: build Persian sparse index
phase2: benchmark hybrid retrieval
phase2: benchmark reranking
phase2: add context builder
phase2: add claim-level citations
phase2: add answerability safety confidence
phase2: add evaluation and ablations
phase2: package reproducible release
phase2: add phase3 handoff contract
```

Commit و Push فقط با مجوز جداگانه انجام می‌شود.

۱۵. تعریف Done هر نوت‌بوک

یک نوت‌بوک فقط زمانی Done است که:

- توضیح فارسی برای مخاطب غیرمتخصص داشته باشد؛
- ورودی نسخه‌دار و Hash آن ثبت شده باشد؛
- تمام سلول‌های Code شماره داشته باشند؛
- Restart & Run All موفق باشد؛
- سلول اجرانشده و Error Output نداشته باشد؛
- Artifact و گزارش مستقل تولید شده باشد؛
- Gate با Assert واقعی PASS شده باشد؛
- Known limitations ثبت شده باشد؛
- شواهد فنی آن به Evidence index اضافه شده باشد؛
- Notebook بعدی بدون استفاده از حافظه این Notebook بتواند خروجی را بخواند.

۱۶. تعریف Done کل فاز ۲

فاز ۲ زمانی کامل است که ۲۴ نوت‌بوک مستقل طبق ترتیب اجرا و تمام Gateها PASS شده باشند؛ سه منبع در Dataset مشترک نسخه‌دار قرار گرفته باشند؛ Retrieval ترکیبی و Reranking با Golden Dataset ارزیابی شده باشند؛ Claim-level Safety، Abstention، Citation و Confidence توضیح‌پذیر فعال باشند؛ و Release قابل بازتولید همراه قرارداد تحویل فاز ۳ ساخته شده باشد.

تعداد زیاد داده یا ساخت Vector Database به‌تنهایی تکمیل فاز ۲ محسوب نمی‌شود.

۱۷. اولین مسیر اجرایی پیشنهادی

1. ساخت و اجرای environment_and_baseline.ipynb_00؛

2. Freeze نوت‌بوک موجود سایت؛

3. اجرای website_acceptance.ipynb_02؛

4. اگر Raw موجود و سالم بود، Crawl مجدد انجام نشود؛

5. اگر بخشی مفقود یا خراب بود، فقط Repair incremental انجام شود؛

6. پس از Website Gate، وارد book_inventory.ipynb_03 شوید.

جمع‌بندی: مسیر صحیح، دورریختن کار فعلی سایت نیست. کار فعلی به‌عنوان Baseline حفظ و با یک Gate مستقل قابل دفاع می‌شود؛ سپس هر بخش فاز ۲ در نوت‌بوک جداگانه، با توضیح فارسی، آزمون، Artifact، گزارش و شاهد دانش فنی پیش می‌رود.