نقشه عملیاتی فاز ۲ RAG_finance

Evaluation و Knowledge Engineering، RAG Core، Citation، Safety

Repository	Shahbazi-Amir/RAG_finance
Branch مبنا	rag-phase2
Commit ممیزی	96c0f0c7d09f4bff107ed71664a0c57ed09f3214
تاریخ نسخه	۲۱ اوت ۲۰۲۶
دامنه	RAG Core؛ خارج از Deployment و پنل شخصی

۱. تعریف Done فاز ۲

فاز ۲ زمانی تمام است که:

- مقاله، کتاب و Transcript هرکدام Pipeline مستقل و قابل تکرار داشته باشند.
- هر Document و Chunk به Raw source و مالکیت/منشأ آن برگردد.
- Embedding، Chunk set، Dataset و Index نسخه‌دار و قابل بازسازی باشند.
- Retrieval با Baselineهای Dense و Sparse مقایسه شده باشد.
- انتخاب Hybrid/Reranker فقط با Benchmark انجام شده باشد.
- پاسخ ساخت‌یافته، Claim-level Citation و Citation verification داشته باشد.
- سؤال بی‌پاسخ، مبهم و پرریسک تشخیص داده شود.
- Golden Dev/Test، Regression gate و گزارش فنی وجود داشته باشد.

۲. مدل منشأ و مالکیت منابع

نباید Curator، Knowledge Owner، Author و Rights Holder با یکدیگر مخلوط شوند.

گروه	content_origin پیشنهادی	نکته ثبت
مقاله مستقیم مؤلف	primary_author	author و knowledge_owner هر دو مؤلف
مقاله زیر نظر سردبیری	editorial_supervised	author واقعی جدا؛ curation_owner مؤلف
کتاب و نوشتار تألیفی	authored_work	work، edition و rights evidence
تدریس و آموزش مؤلف	self_instruction	program، speaker و timestamp
مصاحبه	interview	interviewer/host و speaker جدا
برنامه تلویزیونی	broadcast	broadcaster، episode، speaker و rights evidence

فیلدهای الزامی:

- creator/author
- knowledge_owner
- curation_owner
- rights_holder

- rights_status
- rights_evidence_id
- allowed_uses
- attribution_text
- content_origin

وجود محتوا در Repository به‌تنهایی مدرک حقوق بهره‌برداری نیست. موارد فاقد مدرک در Quarantine باقی بمانند.

۳. جریان کل فاز ۲

Freeze/Baseline ↓ Contracts + IDs + Rights ↓ Website | Book | Video/Audio ↓ Canonical Dataset /Release ↓ Normalize + Source-aware Chunk ↓ Embed + Versioned Index ↓ Dense/Sparse/Hybrid Rerank ↓ Context + Claims + Citation + Safety ↓ Golden Evaluation + Release Candidate

۴. بسته P2-01 - Freeze و Baseline فاز ۱

کارها

- Tag نسخه نهایی Demo و ثبت SHA.
- ثبت ۷۶ Chunk، ۱۶۸ Document، تنظیم Chunk 1200/200 و مدل‌ها.
- اجرای دوباره ۱۰ سؤال موجود و ثبت پاسخ، منابع، latency و خطا.
- ثبت ناهماهنگی Config مدل و محدودیت‌های Known.
- ADR جداسازی فاز ۱ و ۲ و Deprecation plan.

خروجی

- docs/baseline/phase1_baseline.md
- reports/baseline/phase1_results.json
- docs/adr/ADR-000-phase-boundary.md

Gate

نسخه فاز ۱ از محیط تمیز قابل اجرا و نتیجه آن مرجع مقایسه باشد.

۵. بسته P2-02 - Data Contract، Stable IDs و Versioning

کارها

- تعریف JSON Schema برای Citation، Chunk، Document، Source و Dataset Release.
- تعریف Adapter schema برای Website، Book و Video/Audio.
- تعریف ID policy و migration policy.
- ثبت pipeline/extractor/normalizer/chunker version، processed hash، raw hash.
- طراحی Artifact Registry برای Index، Embeddings، Chunks، Dataset و Eval.

خروجی

- schemas/source.schema.json
- schemas/document.schema.json

- schemas/chunk.schema.json
- schemas/citation.schema.json
- schemas/dataset_release.schema.json
- docs/data/id_policy.md
- docs/data/schema_migration.md

Gate

نمونه معتبر و نامعتبر هر سه منبع با تست Schema بررسی شود و IDها deterministic باشند.

۶. بسته P2-03 - Website Pipeline V2

کارها

- انتقال منطق Notebook موفق ۵۲۹ مقاله به Package/CLI.
- extraction، Raw snapshot، Canonical URL، Discovery و validation.
- حفظ origin، tags، date، author، title، URL، article_id و hash.
- Change detection برای NEW/UPDATED/UNCHANGED/MISSING.
- idempotency، backoff، retry، Resume و failure classification.
- گزارش Crawl و Processing مستقل.

Gate

- دو اجرای ورودی ثابت، Manifest و خروجی یکسان بدهند.
- تغییر کنترل‌شده فقط Documentهای متاثر را بازپردازش کند.
- هیچ Empty content به‌عنوان Success ثبت نشود.
- Attribution مقاله مستقیم و سردبیری به‌درستی تفکیک شود.

۷. بسته P2-04 - Book Pipeline

کارها

- ساخت Works/Edition registry برای ۷ فایل موجود و هر نسخه جایگزین.
- پردازش DOCX؛ پشتیبانی PDF/EPUB فقط در صورت وجود ورودی.
- استخراج Chapter/Section/Paragraph و حذف Header/Footer.
- حفظ Raw و تولید location anchor پایدار.
- Page citation فقط با نسخه مرجع صفحه‌بندی‌شده.
- تشخیص exact/near duplicate و ویرایش‌های متفاوت.

Gate

هر قطعه متن به Location، Chapter، Edition، Work و Rights evidence معتبر برگردد.

۸. بسته P2-05 - Video/Audio Transcript Pipeline

کارها

- Registry سری/برنامه/قسمت/رسانه و نوع محتوا.
- Segment schema شامل text، speaker، end_ms، start_ms و verification status.

- Validation ترتیب زمان، duplicate، overlap/gap و empty segment.
- Normalization فارسی بدون بازنویسی معنایی.
- حفظ اصطلاحات مالی، اعداد و نام‌ها.
- ثبت timestamp_unavailable وقتی منبع زمان ندارد؛ عدم جعل زمان.

Gate

هر Transcript به Episode و رسانه اصلی متصل و هر Segment قابل Cite یا صریحاً فاقد Timestamp باشد.

۹. بسته P2-06 - Canonical Dataset و Quality

کارها

- تبدیل سه Adapter به Common Document Model.
- Deduplication در Document، Paragraph و Chunk.
- Quarantine برای rights/schema/quality نامعتبر.
- Quality report بر اساس source type و content origin.
- release manifest، Dataset card و cryptographic hashes.

معیار

- ۱۰۰٪ رکوردهای Release دارای hash، lineage، Schema و rights_status.
- تعداد Missing metadata و Excludedها صریح گزارش شود.
- هیچ عددی درباره کامل بودن بدون Manifest قابل اثبات اعلام نشود.

۱۰. بسته P2-07 - فارسی‌سازی و Source-aware Chunking

کارها

- Normalizer تست‌شده برای Unicode، ی/ک، ZWNJ، اعداد، فاصله و punctuation.
- Offset map میان Raw و Processed برای Citation.
- Chunker جدا برای Book، Website و Transcript.
- حفظ Heading/Chapter/Page-or-anchor/Timestamp.
- آزمایش 300-500، 500-800 و 800-1200 token.
- آزمایش Parent-child و semantic boundaries.

Gate

هیچ Chunk بدون dataset_version، parent/location، document_id و content_hash وارد Index نشود؛ Strategy با Benchmark انتخاب شود.

۱۱. بسته P2-08 - Golden Dataset

طراحی پیشنهادی

حداقل پیشنهادی ۳۰۰ سؤال؛ عدد نهایی پس از Sampling و توان بازبینی تعیین شود:

- سؤال مستقیم، مفهومی، مقایسه‌ای و چندمنبعی.
- Video، Book، Website و Cross-source.
- Entity/number/exact phrase.

- سؤال مبهم، بدون پاسخ، خارج از دامنه و Hard negative.
- درخواست توصیه سرمایه‌گذاری یا پیش‌بینی.
- تعارض دو منبع و سؤال نیازمند تازگی.

هر رکورد

- question، intent، topic، difficulty و source_type.
- gold_spans/locations، gold_documents و expected claims.
- answerability و abstention reason.
- safety label و reviewer decision.

Gate

راهنمای Annotation، توافق بازبینان، Dev/Test 70/30 و Freeze تست نهایی وجود داشته باشد.

۱۲. بسته P2-09 - Embedding و Index V2

کارها

- حفظ text-embedding-3-large به‌عنوان Baseline فاز ۱.
- Benchmark حداقل یک گزینه دیگر روی فارسی پروژه.
- ثبت dimension، cost، latency، Recall و failure rate.
- ساخت Index نسخه‌دار با Payload کامل.
- Delete، Update، Add، Rebuild و Re-index.
- Verification: expected chunks برابر indexed points.

Gate

هر Index به Chunker، Dataset و Embedding release مشخص متصل و از صفر قابل بازسازی باشد.

۱۳. بسته P2-10 - Retrieval Engineering

آزمایش‌ها

1. Dense baseline.
2. BM25/Sparse baseline.
3. Hybrid با RRF و Weighted fusion.
4. Hybrid + Reranker.
5. Metadata filtering و source balancing.

Metrics

- Recall@5/10، Precision@k، MRR، nDCG و Hit rate.
- Context precision/recall و source coverage.
- p50/p95 latency و cost.

Gate

روش نهایی فقط با Experiment matrix و ADR انتخاب شود. افزایش پیچیدگی بدون بهبود معنادار پذیرفته نیست.

۱۴. بسته P2-11 - Context، Generation و Citation

کارها

- Context compiler با token budget، diversity، dedup و source balance.
- جداسازی Evidence از Instruction و کنترل prompt injection داخل سند.
- خروجی ساخت‌یافته Answer، Claims و Citations.
- Citation mapper و verifier برای claim support و location accuracy.
- Conflict handling و بیان اختلاف منابع.
- Cache key شامل همه Versionها و پارامترهای موثر.

Citation

- Website: title، canonical URL و span/section.
- Book: work، edition، chapter و page یا stable anchor.
- Video/Audio: program، episode و start/end timestamp یا segment anchor.

Gate

هر Claim factual دارای Citation معتبر باشد و Citation بازشده دقیقاً Evidence همان Claim را نشان دهد.

۱۵. بسته P2-12 - Answerability، Safety و Confidence

Taxonomy درخواست

- آموزش مالی.
- توضیح مفهوم یا محتوای مؤلف.
- برنامه‌ریزی عمومی.
- سؤال شخصی نیازمند داده.
- توصیه خریدوفروش/سرمایه‌گذاری.
- پیش‌بینی.
- خارج از دامنه.

Confidence

Confidence از source quality، citation entailment، evidence agreement، evidence coverage، answerability margin و freshness ساخته شود؛ score خام Qdrant یا ادعای LLM کافی نیست.

Gate

روی answer/no-answer، Test set و safety جداگانه سنجیده شود و موارد بحرانی پذیرفته‌نشده صفر باشد.

۱۶. بسته P2-13 - Tests، CI و Reproducibility

- Unit: schema، normalization، IDs، hash، chunking، cache و citation.
- Integration: هر Source تا Document/Chunk/Index و Question تا Citation.
- Failure: bad HTML، broken book، invalid transcript، API/Qdrant/LLM failure.
- Regression: سؤال‌های فاز ۱ و Golden smoke.
- CLI، config schema، lockfile، Package و container reproducibility.

- CI برای lint/test/schema/data-quality/eval smoke.

Gate

در محیط تمیز، Release مشخص ساخته و Benchmark منتخب بدون تغییر دستی اجرا شود.

۱۷. بسته P2-14 - مستندات دانش فنی

- Architecture و ADRها.
- Data schema، lineage، rights و dataset cards.
- گزارش فارسی‌سازی، Chunking، Embedding و Retrieval.
- Ablation و failure analysis.
- Citation، hallucination، answerability و safety report.
- Model/System cards و Known limitations.
- ویدیوی اجرای reproducible pipeline.
- مقایسه مستند با «LLM + Vector DB ساده».

۱۸. ترتیب اجرای واقعی

1. P2-01 Freeze/Baseline.
2. P2-02 Contracts/IDs/Rights.
3. P2-03 تا P2-05 به‌ترتیب یا موازی پس از Contract.
4. P2-06 Canonical Release.
5. P2-08 Golden Dataset هم‌زمان با P2-07 Chunking.
6. P2-09 Index.
7. P2-10 Retrieval Benchmark.
8. P2-11 Citation.
9. P2-12 Safety/Confidence.
10. P2-13 Tests/Release و P2-14 Dossier.

۱۹. Gate نهایی و تحویل به فاز ۳

فاز ۲ فقط با این بسته تحویل می‌شود:

- Dataset release ID و Index release ID.
- RAG input/output contract.
- Citation و error/abstention schema.
- Prompt/Policy/Model/Retrieval versions.
- Golden Test report و Regression baseline.
- latency/cost profile محلی.
- health/readiness interface contract.
- release notes، rollback compatibility و known limitations.

Deployment سایت، PostgreSQL، Auth، کاربران، Production monitoring و پنل کاربر متعلق به فاز ۳ هستند.

۲۰. معیارهای پیشنهادی اولیه

این Targetها پس از Baseline و تأیید متخصص دامنه فریز می‌شوند:

معیار	Target اولیه
Data lineage/rights coverage	Release ۱۰۰٪
Citation coverage	حداقل ۹۵٪ Claimهای factual
Citation location accuracy	حداقل ۹۵٪
Unsupported claim rate	حداکثر ۳٪؛ نزدیک صفر در حساس
Safety critical failures	صفر مورد پذیرفته‌نشده
Retrieval	Target پس از Baseline؛ گزارش Recall/MRR/nDCG الزامی
Reproducibility	اجرای کامل از محیط تمیز

۲۱. تصمیم اجرایی

نقشه فاز ۲ قبلی پایه‌ای قوی داشت. اصلاح قطعی این نسخه:

- Deployment از فاز ۲ حذف و به فاز ۳ منتقل شد.
- منشأ سردبیری، تألیف، مصاحبه و پخش تلویزیونی صریح شد.
- حقوق و مدرک انتساب وارد Data Contract شد.
- Citation از Source list به Claim verification ارتقا یافت.
- Golden set از ۱۰۰ سؤال اولیه به طراحی پیشنهادی ۳۰۰ سؤال ارتقا یافت.
- Safety، Confidence و قرارداد تحویل به فاز ۳ به Gate تبدیل شد.

اولین اقدام بعدی: P2-01 و P2-02 را قفل کنید؛ سپس سه Pipeline را روی همان Contract واحد کامل کنید.