چارچوب جامع سؤال‌ها و آزمون‌ها

طراحی، اجرا، نمره‌دهی و اعتبارسنجی محصول RAG_finance

سند اجرایی برای تفکیک Golden Dataset، آزمون آموزشی کاربران، آزمون‌های ایمنی و نظام ارزیابی قابل ممیزی

نوع سند	چارچوب فنی و اجرایی ارزیابی
دامنه	فازهای ۲، ۳ و ۴ پروژه RAG_finance
موضوع	سؤال‌ها، بانک آزمون، نمره‌دهی و ارزیابی عمیق
اصل حاکم	تفکیک آزمون سامانه از آزمون کاربر و آزمون ایمنی
خروجی	Scorecard چندبعدی و Gateهای قطعی انتشار

این سند مسیر طراحی و اعتبارسنجی سؤال‌ها را از منبع تا تصمیم انتشار مشخص می‌کند.

خلاصه مدیریتی

در RAG_finance سه گروه سؤال با سه هدف متفاوت وجود دارد و مخلوط‌کردن آن‌ها اعتبار محصول را از بین می‌برد:

1. **Golden Dataset** برای سنجش خود سامانه RAG؛
2. **آزمون‌های آموزشی کاربران** برای سنجش یادگیری و تعیین مسیر آموزشی؛
3. **سؤال‌های Red-team و ایمنی** برای کشف پاسخ ناایمن، توهم، انتساب اشتباه و توصیه مالی نامجاز.

Golden Dataset از فاز ۲ آغاز می‌شود، آزمون عملیاتی و استقرار در فاز ۳ انجام می‌شود و بانک سؤال آموزشی، نمره‌دهی، تشخیص ضعف و پیشروی تطبیقی متعلق به فاز ۴ است. وجود این عناوین در نقشه راه به معنی تکمیل آن‌ها نیست؛ تکمیل زمانی قابل ادعاست که پیاده‌سازی، Pilot، معیارهای عددی، گزارش خطا و Gate انتشار وجود داشته باشد.

اصل حاکم بر طراحی این بخش چنین است:

> سؤال‌های آزمون سامانه، سؤال‌های آزمون کاربر و سؤال‌های ایمنی باید Dataset، مالک، نسخه، معیار و گزارش مستقل داشته باشند.

۱. تفکیک انواع سؤال

نوع مجموعه سؤال	هدف	استفاده‌کننده	محل اصلی
Golden Dataset	سنجش بازیابی، پاسخ، استناد و نبود پاسخ	تیم فنی و ارزیاب علمی	فاز ۲
آزمون آموزشی کاربران	سنجش یادگیری، تشخیص ضعف و تعیین مسیر	کاربر نهایی و مدیر آموزشی	فاز ۴
Red-team و Safety Questions	کشف رفتار ناایمن، توهم و دورزدن Policy	تیم کیفیت و امنیت	فازهای ۲، ۳ و ۴

این سه مجموعه نباید به یک بانک واحد تبدیل شوند. به‌خصوص سؤال‌های نهایی Golden Dataset نباید در تنظیم Prompt، انتخاب Retrieval، آموزش نمونه‌ای یا آزمون آموزشی کاربران استفاده شوند؛ زیرا در این حالت Test Leakage رخ می‌دهد و Benchmark دیگر معتبر نیست.

۲. Golden Dataset در فاز ۲

Golden Dataset برای امتحان‌کردن خود محصول است، نه کاربر. هر نمونه باید حداقل شامل اطلاعات زیر باشد:

- شناسه پایدار سؤال؛
- متن سؤال و نگارش‌های معادل فارسی؛
- پاسخ مرجع مورد تأیید متخصص؛
- سند یا اسناد مرجع؛
- محل دقیق شاهد در صفحه، بخش یا Timestamp؛
- نوع منبع: مقاله، کتاب، ویدئو یا صوت؛
- نقش محتوا: تألیف مستقیم مؤلف یا محتوای تهیه‌شده زیر نظر سردبیری؛
- نویسنده واقعی، صاحب دیدگاه و بازبین علمی؛
- انتظار Citation و نوع Locator؛
- وضعیت قابل‌پاسخ یا غیرقابل‌پاسخ؛
- سطح دشواری و نوع استدلال؛
- موضوع و زیرموضوع؛
- دلیل صحت پاسخ؛
- Rubric و قواعد ارزیابی؛
- نسخه Dataset و وضعیت تأیید.

هدف‌های ارزیابی فاز ۲

- آیا سند درست در Top-k بازیابی می‌شود؟
- آیا پاسخ فقط از شواهد بازیابی‌شده ساخته می‌شود؟
- آیا Citation به محل واقعی شاهد اشاره می‌کند؟
- آیا نام مؤلف، نویسنده یا نقش سردبیری اشتباه نسبت داده نمی‌شود؟
- آیا سامانه در نبود مدرک معتبر از پاسخ قطعی خودداری می‌کند؟
- آیا پاسخ آموزشی از توصیه خرید یا فروش تفکیک می‌شود؟
- آیا اجرای مجدد روی نسخه ثابت، نتیجه قابل بازتولید می‌دهد؟

قواعد حفاظت از اعتبار Golden Dataset

- مجموعه به Development، Test و Holdout تفکیک شود؛
- Test و Holdout تا پایان تنظیم سیستم قفل بمانند؛
- پاسخ‌های مرجع وارد Prompt تولید پاسخ نشوند؛
- هر تغییر با Version و Change reason ثبت شود؛
- نتیجه هر Release همراه با Hash داده، تنظیمات و نسخه مدل ثبت شود؛
- خطاهای کشف‌شده حذف نشوند و به Failure catalogue اضافه شوند.

۳. نقش فاز ۳ در آزمون محصول

فاز ۳ محل ساخت بانک سؤال آموزشی یا Mastery نیست. مسئولیت آن اثبات این است که محصول مستقرشده در محیط واقعی، همان رفتار پذیرفته‌شده فاز ۲ را با امنیت و پایداری حفظ می‌کند.

موارد اصلی فاز ۳:

- API و قراردادهای ورودی و خروجی؛
- رابط چت و مدیریت Session؛
- Authentication و Authorization؛
- اتصال Backend، Frontend، مدل و پایگاه داده؛
- تست End-to-End؛
- تست بار، تأخیر و خطا؛
- Logging، Trace و Monitoring؛
- Backup، Restore و Rollback؛
- جلوگیری از نشت اطلاعات بین کاربران؛
- اجرای Regression روی نسخه مستقرشده.

فاز ۳ باید قراردادهای لازم برای فاز ۴ را آماده نگه دارد، اما منطق کامل آزمون آموزشی، تشخیص Mastery و برنامه شخصی یادگیری را در خود جذب نکند.

۴. آزمون آموزشی کاربران در فاز ۴

آزمون آموزشی بخشی از حلقه رشد سواد مالی کاربر است، نه صرفاً یک فرم چندگزینه‌ای. ارتباط آن با ماژول‌های فاز ۴ به صورت زیر است:

ماژول	مسئولیت
ماژول ۴	تعریف شایستگی‌ها و اهداف یادگیری
ماژول ۷	طراحی Blueprint آزمون
ماژول ۸	بانک سؤال نسخه‌بندی‌شده و فرایند Review
ماژول ۹	اجرای آزمون و محاسبه قطعی نمره
ماژول ۱۰	تشخیص ضعف، قوت و عدم‌قطعیت
ماژول ۱۴	تمرین، بازخورد و توضیح پاسخ
ماژول ۱۵	Mastery و پیشروی تطبیقی
ماژول ۲۴	مدیریت سؤال‌ها و آزمون‌ها در پنل
ماژول ۲۷	تحلیل یادگیری کاربران
ماژول ۳۰	Benchmark، Regression و Gate انتشار

وجود این ماژول‌ها نشان می‌دهد جای معماری آزمون مشخص شده است؛ بااین‌حال تکمیل واقعی نیازمند کد اجرایی، داده معتبر، تأیید علمی، Pilot و گزارش آماری است.

۵. طراحی و حاکمیت سؤال‌های مؤلف

اگر صاحب دانش سؤال را مستقیماً نوشته باشد، نقش او باید «مؤلف مستقیم» ثبت شود. اگر عضو تیم سؤال را نوشته و صاحب دانش آن را تأیید کرده باشد، نویسنده واقعی و بازبین علمی باید جداگانه ثبت شوند. نویسنده، صاحب دیدگاه، بازبین علمی و ویراستار نباید یک Metadata فرض شوند.

فیلدهای ضروری هر سؤال آموزشی

- question_id

- question_version
- question_author_id
- author_role
- scientific_reviewer_id
- learning_objective_id
- competency_id
- source_evidence_ids
- صورت سؤال؛
- گزینه‌ها یا Rubric پاسخ تشریحی؛
- پاسخ صحیح؛
- توضیح علت صحت پاسخ؛
- توضیح علت نادرستی گزینه‌ها؛
- سطح دشواری اولیه؛
- نوع مهارت مورد سنجش؛
- وضعیت Approved، Review، Draft یا Retired؛
- تاریخ و نسخه تأیید؛
- آمار عملکرد سؤال پس از Pilot.

قواعد نسخه‌بندی سؤال

- سؤال استفاده‌شده در آزمون واقعی مستقیماً بازنویسی نشود؛
- اصلاح در نسخه جدید انجام شود؛
- نسخه قبلی قابل بازیابی باقی بماند؛
- مشخص باشد هر کاربر کدام نسخه را دیده است؛
- دلیل تغییر و تأییدکننده ثبت شود؛
- سؤال نامعتبر Retire شود، نه اینکه تاریخچه آن حذف شود.

فرایند تأیید پیشنهادی

1. تعریف هدف یادگیری و Evidence مورد انتظار؛
2. نگارش سؤال توسط مؤلف یا نویسنده مشخص؛
3. بازبینی علمی و تطبیق با منابع؛
4. بازبینی آموزشی و بررسی ابهام؛
5. کنترل فنی Schema و پاسخ‌نامه؛
6. اجرای Pilot محدود؛
7. تحلیل آماری؛
8. تأیید، اصلاح نسخه یا Retire؛
9. پایش مستمر پس از انتشار.

۶. نمره‌دهی: کد قطعی یا مدل زبانی

سؤال‌های دارای پاسخ قطعی

در سؤال‌های چندگزینه‌ای، درست/نادرست، تطبیق مفاهیم، ترتیب مراحل و پاسخ عددی دارای دامنه مشخص، نمره باید توسط کد قطعی محاسبه شود. برای ورودی یکسان باید همیشه نتیجه یکسان تولید شود و نسخه Answer key ثبت گردد.

سؤال‌های تشریحی

استفاده از مدل زبانی فقط در نقش داور کمکی مجاز است و باید شرایط زیر رعایت شود:

- Rubric دقیق قبل از مشاهده نتایج تعریف شود؛
- پاسخ مرجع و شواهد معتبر در اختیار داور باشد؛
- خروجی ساخت‌یافته همراه با نمره، Reason code و شاهد تولید شود؛
- داور روی نمونه‌های داوری‌شده انسانی Calibration شود؛
- نرخ خطای داور گزارش شود؛
- پاسخ‌های حساس، مرزی یا کم‌اطمینان به بازبینی انسانی ارجاع داده شوند؛
- مدل داور ترجیحاً از مدل پاسخ‌دهنده مستقل باشد؛
- نمره مدل به‌تنهایی مبنای تصمیم حساس یا نهایی نباشد.

مدل زبانی جایگزین تست قطعی کد، کنترل مالکیت محتوا، بررسی Locator واقعی یا اجرای Policy نیست.

۷. لایه‌های تست عمیق

۷.۱ تست‌های نرم‌افزاری

- Schema validation؛
- Unit test؛
- Contract test؛
- Integration test؛
- End-to-End test؛
- Migration test؛
- Backup/Restore test؛
- Regression test.

این تست‌ها صحت عملکرد نرم‌افزار را می‌سنجند، اما به‌تنهایی کیفیت علمی پاسخ را اثبات نمی‌کنند.

۷.۲ ارزیابی Data Pipeline

- هیچ سندی گم یا دوباره‌شماری نشده باشد؛
- متن ناقص یا مخدوش استخراج نشده باشد؛
- عنوان، نویسنده، صاحب دیدگاه، ویراستار و نقش منبع صحیح باشد؛
- شماره صفحه، URL و Timestamp حفظ شده باشد؛
- Stable ID بدون دلیل تغییر نکرده باشد؛
- Chunk از مرز معنایی نامناسب عبور نکرده باشد؛

- Deduplication محتوای معتبر را حذف نکرده باشد؛
- Manifest با فایل واقعی سازگار باشد؛
- اجرای مجدد نتیجه قابل‌تکرار تولید کند.

۷.۳ ارزیابی Retrieval

- Recall@k
- Precision@k
- MRR
- nDCG
- Hit rate منبع صحیح؛
- Recall تفکیکی سایت، کتاب و Transcript؛
- Recall تفکیکی تألیف مستقیم و محتوای زیر نظر سردبیری؛
- عملکرد روی فارسی رسمی، محاوره‌ای و نگارش‌های متفاوت؛
- عملکرد سؤال‌های Cross-source.

۷.۴ ارزیابی پاسخ و Citation

- Correctness پاسخ؛
- Groundedness یا Faithfulness؛
- Citation precision؛
- Citation recall؛
- Citation completeness؛
- اعتبار Timestamp، Page و URL locator؛
- صحت انتساب به مؤلف یا نویسنده؛
- نرخ ادعاهای بدون شاهد؛
- نرخ استناد به منبع اشتباه.

۷.۵ نبود پاسخ و ایمنی

- Precision، Recall و F1 تشخیص نبود پاسخ؛
- نرخ پاسخ قطعی در نبود مدرک؛
- نرخ توصیه مستقیم خرید یا فروش؛
- تفکیک آموزش مالی از مشاوره سرمایه‌گذاری شخصی؛
- مقاومت در برابر Prompt injection؛
- جلوگیری از استخراج غیرمجاز اطلاعات؛
- جلوگیری از افشای اطلاعات کاربر دیگر؛
- عملکرد روی سؤال‌های جهت‌دار، متعارض و مبهم.

۷.۶ اعتبار آزمون آموزشی

پس از Pilot واقعی باید موارد زیر بررسی شوند:

- دشواری هر سؤال؛
- قدرت تفکیک سؤال؛
- تحلیل گزینه‌های انحرافی؛
- پایایی آزمون؛
- اعتبار محتوایی و پوشش اهداف یادگیری؛
- پیش‌آزمون و پس‌آزمون؛
- Learning gain؛
- Retention در بازسنجی بعدی؛
- دقت تشخیص Mastery؛
- تأثیر برنامه شخصی بر یادگیری؛
- تفکیک نرخ تکمیل از یادگیری واقعی؛
- بررسی انصاف فقط در صورت وجود رضایت، داده و حجم نمونه کافی.

حد پذیرش این معیارها نباید پیش از Baseline و Pilot حدس زده شود. Targetها باید بعد از مشاهده داده واقعی، با ثبت حجم نمونه و عدم‌قطعیت Freeze شوند.

۷.۷ عملیات و محصول

- Latency؛
- Availability؛
- Error rate؛
- ظرفیت کاربران هم‌زمان؛
- هزینه هر پاسخ؛
- هزینه هر واحد آموزشی تکمیل‌شده؛
- عملکرد Cache؛
- موفقیت Backup/Restore؛
- Audit coverage؛
- عدم نشت داده بین کاربران.

۸. آیا یک دستگاه یا امتیاز نهایی وجود دارد؟

هیچ دستگاه فیزیکی یا سامانه جهانی معتبری وجود ندارد که یک محصول RAG را دریافت کند و یک نمره قطعی و نهایی ارائه دهد. راه درست، ساخت یک **Evaluation Harness اختصاصی** برای پروژه است.

این سامانه باید شامل اجزای زیر باشد:

- Datasetهای نسخه‌بندی‌شده؛
- Benchmark runner؛
- Metric calculators؛

- داوری انسانی؛
- داور مدل کالیبره‌شده؛
- Regression suite؛
- Dashboard؛
- Failure catalogue؛
- Release gates؛
- گزارش قابل ممیزی.

ابزارهای عمومی می‌توانند اجرای تست و محاسبه معیارها را آسان کنند، اما تعریف حقیقت، پاسخ مرجع، Rubric، خطاهای بحرانی و معیار پذیرش باید در مالکیت خود پروژه باشد.

۹. Scorecard چندبعدی و Gateهای بحرانی

یک امتیاز کلی به‌تنهایی گمراه‌کننده است؛ زیرا ممکن است پاسخ روان باشد ولی Citation غلط، یا Retrieval قوی باشد ولی توصیه مالی ناایمن تولید شود.

بُعد	خروجی ارزیابی
کیفیت بازیابی	Retrieval score
صحت پاسخ	Answer quality score
استناد	Citation score
ایمنی	Safety score
تشخیص نبود پاسخ	Abstention score
یادگیری	Educational effectiveness
شخصی‌سازی	Personalization score
عملیات	Reliability score
حاکمیت	Reproducibility score

در کنار Scorecard باید Gateهای P0 وجود داشته باشند که قابل میانگین‌گیری نیستند:

- افشای داده کاربر دیگر باید صفر باشد؛
- انتساب اشتباه جدی به مؤلف باید صفر باشد؛
- Citation locator بحرانی نامعتبر باید صفر باشد؛
- توصیه خرید یا فروش برخلاف Policy باید صفر باشد؛
- شکست Backup/Restore یا نبود Rollback قابل قبول نیست.

حتی با امتیاز کلی بالا، شکست در یک Gate بحرانی باید انتشار نسخه را متوقف کند.

۱۰. روند اجرایی ارزیابی و انتشار

1. **Freeze**: نسخه Knowledge Base، مدل، Policy، Retrieval، Prompt و Dataset ثبت شود.
2. **Pilot**: پروتکل روی زیرمجموعه محدود اجرا و ایراد ابزار، Rubric و داوری کشف شود.
3. **Calibration**: داوری ماشینی با داوری انسانی تنظیم و Thresholdها تثبیت شوند.
4. **Benchmark**: همه سامانه‌ها روی Test set قفل‌شده اجرا شوند.

5. تحلیل: نتایج کلی و تفکیکی، هزینه، تأخیر، بازه اطمینان و Failure case گزارش شوند.

6. Ablation: اجزای اختصاصی یکی‌یکی حذف شوند تا سهم واقعی آن‌ها مشخص شود.

7. تصمیم Release: در صورت شکست Gateهای P0 انتشار متوقف و نسخه برای اصلاح بازگردانده شود.

۱۱. سند تکمیلی مورد نیاز در نقشه راه

برای جلوگیری از پراکندگی تست‌ها بین فازها، یک سند مستقل با عنوان زیر باید به مجموعه مستندات پروژه اضافه شود:

برنامه جامع ارزیابی، آزمون و اعتبارسنجی RAG_finance

این سند باید موارد زیر را یکپارچه کند:

- تفکیک Golden Dataset و بانک سؤال آموزشی؛
- تقسیم Development، Test و Holdout؛
- دستورالعمل طراحی و بازبینی سؤال؛
- فرایند تأیید مؤلف و بازبین علمی؛
- Rubric داوری؛
- فرهنگ‌نامه Metricها و فرمول محاسبه؛
- روش Pilot و تحلیل آماری؛
- معیارهای Release gate؛
- پروتکل Benchmark و مقایسه Baselineها؛
- برنامه Regression؛
- قالب گزارش Benchmark؛
- مسئول هر تست در فازهای ۲، ۳ و ۴؛
- Evidence pack قابل ارائه به کارفرما و ارزیاب فنی.

نتیجه نهایی

جای اصلی انواع سؤال در نقشه فعلی مشخص است: Golden Dataset در فاز ۲، آزمون استقرار در فاز ۳ و آزمون آموزشی و شخصی‌سازی در فاز ۴. آنچه باید تقویت شود، اتصال رسمی این سه فاز به یک برنامه ارزیابی واحد، نسخه‌بندی‌شده و قابل ممیزی است.

تکمیل این بخش فقط با وجود بانک سؤال یا چند تست خودکار اثبات نمی‌شود. محصول زمانی قابل دفاع است که سؤال‌ها دارای Lineage و نسخه باشند، نمره‌دهی قطعی از داوری زبانی تفکیک شود، Pilot واقعی انجام شود، معیارها پس از داده واقعی Freeze شوند و هیچ Release بدون عبور از Gateهای علمی، ایمنی و عملیاتی منتشر نشود.